

1 Weighted Ensemble을 활용한 다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

Weighted Ensemble을 활용한

다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

*

Cross-Asset Variance Risk Premium Forecasting Across Multiple Horizons Using a Weighted Ensemble Approach

*

지원기관표기

요 약

본 연구는 주식(5), 채권(3), 원자재(3)로 구성된 11개 ETF를 대상으로, 공개 OHLCV 데이터와 VIX 기간구조 지표를 이용해 분산 위험 프리미엄(VRP)을 예측하는 프레임워크를 제시한다. 예측 지평은 거래일 기준 1, 5, 22, 60, 90, 120, 180, 252의 8개 구간이며, (1) 전방 실현분산을 먼저 예측하고 (2) 내재분산 프록시와 결합해 VRP를 산출하는 2단계 구조를 사용한다. 동일한 피쳐와 동일한 검증 절차 하에서 선형(정규화 회귀), 트리, 딥러닝(시계열) 모델을 비교한 결과, 예측 지평에 따라 유리한 모델 구조가 달라지는 경향이 확인되었다. 1~22거래일에서는 정규화 선형 모델이, 60~90거래일에서는 시계열 신경망이, 180~252거래일에서는 트리 기반 모델이 상대적으로 안정적인 성능을 보였다. 추가로 통계적 유의성 검정과 만기 불일치-결측 처리-자산특화 지표 대체 등 강건성 검증을 통해 제안 방법의 신뢰도를 점검하였다.

Abstract

1.

Keywords

*

□

I. 서 론

최근 [코로나 팬데믹(2020 VIX 82.7), 러우 전쟁 (2022 VIX 36.5), 이란 전쟁(2026 VIX 27.3), AI 붐 (2023~2025 변동성 급증]으로 자산 변동성이 폭증하며 자산 변동성 예측 관심이 증가하고 있다.

금융시장에서 변동성은 "가격이 얼마나 흔들리는 가"를 나타내는 지표를 넘어, 투자자의 불확실성 평가와 이에 대한 보험료(위험 프리미엄)를 반영한다. 특히 옵션시장은 미래 위험에 대한 기대가 가격에 포함되므로, 옵션가격으로 계산되는 변동성 지표는 시장의 전방향 기대(forward-looking expectation)를 담고 있는 자료로 자주 활용된다. 대표적으로 Cboe 변동성지수(VIX)는 S&P 500 옵션 가격을 이용해 향후 30일 기대 변동성을 측정하도록 설계된 지수다.

변동성 연구는 크게 두 가지 질문으로 나뉜다. 첫째는 "미래 변동성의 수준이 얼마나 될까?"이고, 둘째는 "그 위험이 시장에서 얼마나 비싸게 가격화될까?"이다. 실현분산(realized variance, 이하 RV)은 주로 첫 번째 질문과 관련이 있고, 분산 위험 프리미엄(variance risk premium, 이하 VRP)은 두 번째 질문과 더 직접적으로 연결된다. VRP는 위험중립 기대분산(옵션시장이 반영한 기대)과 물리적 기대분산(실제로 실현되는 분산의 기대)의 차이로 이해되며, 변동성 위험의 가격화(price of volatility risk)를 나타낸다.

금융 예측에서 가장 직관적인 목표는 수익률(또는 초과수익률)이다. 그러나 수익률은 예측 신호가 약하고 잡음이 커서, 학습 구간에서 잘 맞더라도 미래 구간에서 안정적으로 재현되기 어렵다는 점이 반복적으로 보고되어 왔다. [Gu, Kelly, Xiu [1]는 다양한 기계 학습 방법을 비교하며 자산위험프리미엄 측정의 가능성을 보여주지만, 동시에 금융 예측이 구조적으로 어려운 문제임을 분명히 한다.

반대로 RV는 수익률보다 예측이 상대적으로 쉽다. 변동성은 군집(volatility clustering)과 지속성이 강해 과거 정보가 미래에 일부 남는 경향이 있기 때문이다. Corsi [2][3]의 HAR-RV는 일/주/월(거래일 기준 1/5/22일) 규모의 변동성 정보를 결합해 이런 지속성을 간단히 반영하는 대표 모형이다. 또한 Christensen, Siggaard, Veliyev [4]은 여러 기계학습 알고리즘이 HAR 계열과 비교해 실현분산 예측에서 경쟁력을 가질 수 있음을 보였다.

다만 RV 예측은 "위험의 크기"를 맞추는 문제에 가깝다. 즉 RV를 정확히 예측하더라도, 투자자가 해당 위험을 감수하는 대가로 요구하는 변동성 위험 프리미엄의 수준까지 직접 파악할 수는 없다. 옵션 시장은 미래 분산 기대뿐 아니라 위험회피 성향과 보험 수요가 함께 반영되므로, 위험이 어떻게 가격화되는지를 파악하려면, 시장의 기대인 내재분산(IV)과 실제 변동성인 실현분산(RV) 간의 차이(Premium)

메모 포함[1]: 수치 출처 기입 필요

메모 포함[6]: 참고문헌 인용 형식에서 저자 표기는 1저자만 기재한 후 나머지는 et al.로 표기하는 방식으로 통일할 필요가 있음.

메모 포함[2]: 현재 서술 방식이 나열식으로 구성되어 있어 문맥의 연결성이 다소 부족하게 느껴짐. 해당 사건이 자산 변동성 증가로 이어진 이유에 대한 간단한 설명을 보완할 필요가 있음.

메모 포함[3]: 논문 전반에서 “ ” 기호를 사용하여 문장을 설명하는 표현이 다수 확인됨. 해당 방식은 학술 논문의 일반적인 서술 형식과는 다소 맞지 않으므로 전체적으로 서술형 문장으로 수정이 필요함.

메모 포함[4]: 영어 표현을 사용할 경우 약어와 전체 표현을 함께 제시하는 방식(약어, Full English Expression)으로 작성할 필요가 있음. 또한 영어 표기에서 문장 첫 글자가 소문자로 작성된 부분은 대문자로 수정이 필요함.

메모 포함[5]: 논문 전반에서 괄호를 활용한 설명식 표현이 많이 사용되고 있음. 괄호 대신 “~를 뜻하는 ~은”과 같은 서술형 표현으로 수정하고, 한국어 문장에서도 가능한 경우 괄호 표현을 풀어 서술하는 방식으로 보완할 필요가 있음.

3 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

구조를 살펴보아야 한다. Carr and Wu [5]는 옵션 포트 내재분산, 실현분산, 그리고 분산 위험 프리미엄의 폴리오로 위험중립 기대분산(분산스왑 레이트)을 근 개념적 성질을 보여주는 예시가 표 2에 제시되어 있다. 예를 들어, 시장이 미래 추가 급락 위험을 높게 평가하여 옵션 프리미엄을 비싸게 지불하면 내재분

산(주로 VIX를 통해 대리)이 크게 치솟으며, 이후 실제 시장의 혼란(실현분산)이 그에 미치지 못한다면

VRP는 양(+)의 값을 띠게 된다. 반면, 예측하지 못한 극단적인 시장 충격이 발생했을 때는 실현분산이 내재분산을 상회하여 VRP가 음(-)의 값으로 나타날 수 있다. 즉, VRP는 시장이 변동성 변동 위험을 스스로 얼마나 비싸게 평가하고 이에 대한 대가를 지불했는지를 본질적으로 드러내는 척도로 작용한다.

표 1. 주요 기호 및 정의

Symbol	Definition
$RV_{i,t}(h)$	Forward RV of asset i, h trading days ahead (annualized)
IV_t^2	Implied variance proxy, $(VIX_t / 100)^2$
$VRP_{i,t}(h)$	Variance risk premium, $IV_t^2 - RV_{i,t}(h)$
h	Forecast horizon (trading days), $h \in \{1, 5, 22, 60, 90, 120, 180, 252\}$
i	Asset index ($i=1, \dots, 11$; 11 ETFs)
t	Time index (trading day)
r_t	Daily log return, $\ln(P_t/P_{t-1})$
R^2	Coefficient of determination; pooled and median R^2

대표 주가지수인 S&P 500 (SPY) ETF를 활용하여

표 2. SPY 변동성 지표 예시와 VRP 직관 요소 (연율화 분산)

Scenario	IV_t^2	$RV_t(h)$	VRP
Normal	0.0225 (VIX15)	0.0144	0.0081(+)
Panic (pre-priced)	0.1600 (VIX40)	0.0625	0.0975 (strong+)
Surprise shock	0.0400 (VIX20)	0.0900	-0.0500(-)

용어와 산출 절차의 상세 정의는 3장(3.4-3.6절)에서 기술한다.

본 연구의 예측 지평은 모두 거래일 기준이며, $h \in \{1, 5, 22, 60, 90, 120, 180, 252\}$ 설정한다. 상세 설정과 정화 구간(purge gap) 처리는 3장 3.3절에서 기술한다.

VRP 관련 연구는 (i) VRP의 측정과 추정, (ii) VRP의 경제적 의미와 자산가격 함의, (iii) 특정 시장(주로

메모 포함[7]: 측정 가능하다는 것과 아래 예측 대상으로 설정한다는 건 다른 이야기. VRP를 예측하면 어떤 의사결정에 유용한지에 대한 내용이 없음 (VRP가 추가적으로 가지는 정보가 뭔지, 그게 왜 유용한지)

메모 포함[8]: 서론은 연구에서 해결하고자 하는 문제의 배경과 필요성을 제시하는 부분으로, 기존 연구를 단순히 나열하는 서술은 다소 부적절하게 느껴짐. RV 예측의 변천사와 같은 내용은 Related Work 섹션으로 이동하여 정리하는 것이 필요함.

메모 포함[9]: 변수 설명은 서론이 아닌 방법론, 혹은 실험 파트 옮길 필요가 있으며, 식은 따로 빼는 것을 추천함 해당 부분의 변수 설명은 서론보다는 방법론 또는 실험 파트로 이동하는 것이 적절함. 또한 수식은 문장 내에 포함하기보다는 별도의 식으로 분리하여 제시하는 것을 권장함.

메모 포함[10]: 앞선 코멘트와 동일하게 해당 내용은 실험 혹은 방법론에 작성하는 것을 권장함

4 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

주식지수) 중심의 실증 분석으로 축적되어 왔다. 그러나 "VRP 예측" 관점에서는 다음의 공백이 남아 있다.

첫째, 다중 자산 VRP 연구는 대체로 자산별 옵션 자료에 의존한다. 반면 실제 분석 환경에서는 주식-채권-원자재 전체에 대해 장기간 옵션 데이터를 확보하기 어렵다. 본 연구는 11개 ETF의 일별 OHLCV와 공개 변동성 지표를 결합하여, 다중 자산 VRP 예측을 재현 가능한 형태로 구성한다.

둘째, VRP 연구는 월간(대략 30일) 지표(VIX)에 정렬된 분석이 많아, 1~5거래일부터 연간(252거래일)까지 지평을 확장했을 때 예측 구조가 어떻게 달라지는지에 대한 체계적 비교가 충분하지 않다.

셋째, 금융 데이터는 구조 변화가 잦고 노이즈가 큰 편이어서 "복잡한 모델이 항상 더 낫다"고 말하기 어렵다. 그럼에도 동일한 피쳐-동일한 검증 절차 아래에서 선형 모델, 트리 기반 모델, 시계열 신경망 모델을 지평별로 공정 비교한 결과는 제한적이다.

이 공백을 바탕으로 본 연구는 다음 연구 질문에 답한다.

RQ1. 공개 데이터(가격 기반 피쳐와 변동성 지표)를 이용해 구성된 VRP_hat은 주식-채권-원자재 자산군에서 예측 가능한가?

RQ2. 예측 지평이 1거래일에서 252거래일까지 길어질 때, 예측 성능(R^2 , RMSE)과 유효 피쳐는 어떻게 달라지는가?

RQ3. 동일한 피쳐와 동일한 시계열 검증 절차에

서, 선형-트리 기반-시계열 신경망 모델의 상대적 성능은 지평에 따라 어떻게 달라지는가?

RQ4. VRP_hat 예측의 통계적 우위가 실제 거래비용을 반영한 경제적 의사결정(예: 변동성 타이밍 전략)에서도 실효성을 가지는가?

본 연구는 주식(5), 채권(3), 원자재(3)로 구성된 총 11개 ETF(SPY, QQQ, IWM, EFA, EEM, TLT, IEF, AGG, GLD, SLV, USO)를 대상으로 2010년 1월부터 2025년 1월까지 일별 OHLCV 데이터를 사용한다.

피쳐는 (i) HAR 구조 기반의 기본 피쳐, (ii) OHLC로부터 계산한 range 기반 변동성 피쳐, (iii) VIX 기간 구조(예: VIX3M, VIX9D 등)와 같은 변동성 지표 피쳐, (iv) 거래량 기반 피쳐로 구성한다. 또한 단일 VIX를 모든 지평의 타겟 IV로 대체할 때 발생하는 만기 불일치(maturity mismatch) 문제를 점검하고, VIX 기간구조 지표(VIX9D, VIX3M)로 이를 부분적으로 보완한다. 1~5d 지평에서는 VIX9D 대체가 소폭 유리하나, 월간 이상에서는 VIX 단독이 크게 열등하지 않다는 사전 검증 결과를 포함한다.

원자재의 경우 주식 기반 VIX가 충분하지 않을 수 있으므로, 금(GVZ), 원유(OVX) 등 자산특화 변동성 지표를 대체 적용하는 강건성 검증을 수행한다(소폭 개선이 있으나 전체 성능 변화는 제한적).

성능 평가는 R^2 (설명력)과 RMSE(예측오차)를 기반으로, 시간순 학습/테스트 분할과 확장 윈도우 교차검증을 적용한다.

본 논문의 구성은 다음과 같다. 2장에서는 VRP 측정-예측 관련 선행연구를 정리한다. 3장에서는 데이

메모 포함[15]: RQ가 독립적으로 나열되어 있음 서로 논리적으로 관계가 있으면 좋을 것 같음

메모 포함[11]: 대체로와 같은 모호한 표현은 서술의 명확성을 저하시킬 수 있으므로 가능한 경우 구체적인 표현으로 수정하는 것을 권장함.

메모 포함[12]: 해당 문장은 문장 간 논리적 연결이 다소 부자연스럽게 느껴짐. 옵션 데이터 확보의 어려움이 왜 재현 가능한 형태의 VRP 예측 구성으로 이어지는지 인과 관계가 충분히 설명되지 않아 연구의 의도를 명확히 이해하기 어려움. 해당 부분의 설명을 보다 명확히 보완할 필요가 있음.

메모 포함[16]: 서론에서는 사용한 데이터에 대해 간략히 언급하는 수준이 적절하며, 구체적인 데이터 설명은 실험 파트의 데이터셋 섹션으로 이동하는 것이 필요함. 또한 데이터의 규모 및 세부 정보는 표 형태로 정리하여 제시하는 것을 권장함.

메모 포함[13]: 정렬된 분석이 많다는 현의 의미가 다소 모호하게 느껴짐. 해당 분석 방식이 무엇을 의미하는지 구체적인 설명이 필요하며, 이러한 접근이 왜 연구의 한계로 이어지는지에 대한 보완 설명이 필요함.

메모 포함[14]: 문장 전반의 표현이 다소 어색하게 느껴짐. 또한 연구 질문에 답한다는 표현보다는 ~를 제한한다와 같은 서술 방식이 학술 논문에서 보다 일반적으로 사용되므로 해당 표현의 수정이 필요함.

5 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

타·변수 구성 및 방법론을 제시한다. 4장에서는 실험

결과와 논의를 보고하고, 5장에서 결론 및 향후 과제를 정리한다.

2.2 VRP 추정 및 엄밀성

VRP는 옵션 가격오차나 실현분산 추정오차의 영향을 받을 수 있어, 측정의 엄밀성이 중요하다. Zhang, Chen, Lu [9]는 옵션 가격오차(pricing errors)가 존재할 때 내재분산과 VRP를 일관되게 추정하기 위한 비모수 추정법(nonparametric method)과 점근 추론 체계(asymptotic inference)를 제시했다.

이러한 연구는 VRP를 단순 지표로 쓰는 것을 넘어, 추정치의 신뢰도와 이후 예측검정의 타당성을 높이는 방향으로 문헌을 확장한다.

2.3 VRP의 예측력과 시장 간 전이(Spillover)

VRP는 단일 시장을 넘어 다른 시장으로 전이될 수 있다. 예를 들어 M. Hattori, I. Shim, and Y. Sugihara [10]는 분산 위험 프리미엄과 자금 흐름을 통해 주식시장 간 전이 구조를 분석했다. 또한 원자재 영역에서는 VRP가 미래 원자재 수익률과 관련될 수 있으며 [11], 실증에서 주식 VRP를 통제 변수로 포함해도 예측 관계가 유지될 수 있다는 결과가 보고되었다.

이 문헌은 "대표 시장(주식)에서 관측되는 변동성 위험 가격 정보가 다른 자산군에도 영향을 줄 수 있다"는 가능성을 시사한다. 본 연구는 이러한 맥락에서, 공통 변동성 지표(VIX 및 기간구조)를 활용하여 다중 자산(cross-asset)에 범용으로 적용 가능한 VRP 대용치(proxy)를 구축하고 그 예측 가능성을 실증한

II. 관련 연구

2.1 VRP의 정의와 측정

VRP는 위험중립 기대분산과 물리적 기대분산의 차이로 정의되며, 실증에서는 옵션 가격으로부터 위험중립 기대분산(분산스왑 레이트)을 근사하고 실현분산과의 차이로 VRP를 산출하는 방식이 널리 사용된다. Carr and Wu [5]는 옵션 포트폴리오가 분산스왑 레이트를 잘 근사할 수 있음을 보이고, 실현분산과의 차이를 VRP로 정의하는 방법을 제시했다.

또한 VRP는 변동성 수준과 구분되는 경제적 의미를 가진다. Bekaert and Hoerova [6]는 VIX²를 "조건부 기대 실현분산 + 분산 프리미엄"으로 분해하고, 분산 프리미엄이 추가 수익을 예측과 연결될 수 있음을 분석했다. Bollerslev, Tauchen, Zhou [7]는 VRP가 주식 수익률의 시계열 예측에 유의미한 설명력을 가진다는 실증 결과를 제시하였으며, Drechsler and Yaron [8]는 VRP의 변동이 경제 구조(장기 위험)와 연결되는 이론적 메커니즘을 규명하였다. 이 결과는 VRP가 단순히 "변동성이 크다/작다"가 아니라, 위험이 얼마나 비싸게 거래되는지를 보여주는 지표임을 뒷받침한다.

메모 포함[17]: 소단원 제목인 VRP의 정의와 측정은 VRP와 같이 명사 형태로 간결하게 수정하는 것이 필요함. 소단원 제목은 설명식이나 나열식 표현보다는 명사 중심으로 작성하는 것이 일반적인 학술 논문 작성 방식에 보다 적절함.

메모 포함[18]: 인용 뒤 번호

메모 포함[19]: 해당 부분은 관련 연구를 설명하는 내용임으로 단락을 구분하기보다는 동일한 단락에서 이어 서술하는 것이 적절해 보임. 단락 구분은 본 연구에서는과 같이 본 연구의 내용을 설명하는 부분에서 시작하는 것이 바람직함.

메모 포함[20]: 관련 연구 마지막에 한번에 정리하는게 어떨지

6 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측
다.

표 3. 변동성 예측 모델 계보 타임라인

2.4 변동성(RV) 예측

VRP는 IV와 RV의 차이이므로, RV 예측 방법론과도 밀접하게 연결된다. 전통적 GARCH 모형 [12][13] 등에서 출발한 변동성 예측 연구는, 근래에 다양한 시간 스케일의 변동성 성분을 결합해 지속성을 모형화하는 HAR-RV [2][3] 등으로 발전하였다. 이러한 선행 연구 기반 위에서, 최근에는 기계학습이 HAR 계열을 얼마나 향상시킬 수 있는지 확인하는 비교 연구가 늘어나고 있다. [4]은 정규화 회귀, 트리 기반 방법, 신경망 등을 비교하며, 추가 피처가 존재할 때 기계학습이 변동성 예측에서 경쟁력 있음을 보였다.

본 연구는 HAR 기반 피처를 기본으로 두고(range 기반 피처, 변동성 지표 기간구조, 거래량 피처를 추가) 예측 성능이 실제로 얼마나 개선되는지, 그리고 그 개선이 지평에 따라 달라지는지를 함께 살펴본다.

표 3은 GARCH(1986)부터 본 연구(2025)까지 변동성 예측 모델의 안정적 성능 확보 과정을 시간순으로 정리한 것이다. 전통 계량경제 모형(GARCH, HAR-RV)이 기반을 형성하고, LASSO-HAR(2016)과 RF(2023) 등 기계학습 모형이 점진적 개선을 이루었으며, 본 연구의 ElasticNet-59(확장 59피처, L1+L2 정규화)이 22d 롤링 R^2 0.807로, 본 연구 설정 하에서 기존 문헌과 비교되는 높은 성능 위치에 있음을 보여준다.

Year	Model	Category	22d R^2
1986	GARCH (Bollerslev)	Traditional	0.55
2007	HAR-CJ (Andersen+)	Traditional	0.752
2009	HAR-RV (Corsi)	Traditional	0.761
2016	LASSO-HAR (Audrino+)	ML	0.79
2019	ML+Options (Carr+)	ML	0.39
2023	RF (Christensen+)	ML	0.77
2026	BiLSTM-A (Ours)	DL	0.780
2026	WEEns	This study	0.803
2026	ElasticNet-59	This study	0.807

각 모델의 R^2 값은 해당 원저에서 보고된 대표 성능치이며, 서로 다른 데이터셋·피처·대상 자산평가 방식에서 산출된 결과이므로 직접적인 모델 간 우열 비교에 사용할 수 없다. 본 연구 모델에 대한 동일 조건 공정 비교 결과는 4.4절 표 11을 참조한다.

2.5 VRP 예측·활용에서의 기계학습 접근

VRP 관련 기계학습 연구는 크게 두 방향으로 나뉜다. 첫째, 옵션 단면 정보를 직접 사용해 미래 분산(또는 VIX 스타일 지표의 오차)을 예측하는 접근이다. [14]은 옵션 단면을 이용해 미래 실현분산과 "VIX² - RV"와 같은 편차를 학습하는 방법을 논의했

메모 포함[21]: 인용 방법?

메모 포함[22]: 위의 피드백과 같음. 마지막에 한 번에 정리하는게 어떤지

메모 포함[25]: 직접적인 우열 비교에 사용될 수 없다고 하면서 비교 결과를 보여주는 건 상충되는 것 같음

메모 포함[23]: 인용 번호

메모 포함[24]: 비교 성능 평가는 연구 방법 또는 실험 결과와 관련된 내용이므로 서론이 아닌 방법론 또는 실험 파트에서 다루는 것이 적절해 보임. 해당 내용을 관련 섹션으로 이동하여 정리하는 것을 권장함

7 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

다(옵션 데이터가 필요하다는 점에서 데이터 비용이 크다).

둘째, VRP 수확 전략의 타이밍을 개선하는 접근이다. [15]는 EUR/USD 시장에서 일주일 만기 스트레들 메도 전략을 기반으로, 기계학습과 대안 데이터를 활용해 불리한 거래를 회피하는 타이밍 전략을 제안했다. 이 흐름은 VRP 예측이 값 자체의 정확도뿐 아니라, 실제 의사결정의 품질 향상과도 연결될 수 있음을 보여준다.

본 연구는 옵션 단면 데이터를 직접 사용하지 않고, 공개 데이터 기반으로 VRP 예측이 어느 정도 가능한지, 그리고 지평/자산군/모형 복잡도에 따라 어떤 구조적 차이가 나타나는지를 체계적으로 비교한다.

2.6 다중 자산 VRP 연구와 본 연구의 위치

최근에는 여러 자산(주식, 채권, 통화, 원자재 등)에서 VRP를 측정하고 비교하는 연구도 등장했다. [16]는 20개 선물 옵션을 대상으로 분산 위험 프리미엄을 비교하며 자산별 이질성을 보고했다. 하지만 기존 연구는 대체로 각 자산별 전용 옵션 데이터에 의존한다. 본 연구는 실무적 데이터 확보의 제약을 극복하기 위해 공개 지표 기반의 VRP-proxy를 도입하며, 그 과정에서 발생할 수 있는 한계(VIX 만기 불일치, 원자재 시장의 특수성 등)를 명시하고 대안 지수 및 기간구조를 이용한 강건성 점검을 함께 제시한다.

Carr and Wu(2009)의 VRP 표준 정의로부터, Bekaert

and Hoerova(2014)의 VIX 분해, Heston and Todorov(2023)의 cross-asset 비교까지 문헌이 확장되어 왔으며, 본 연구(2025)는 ML/DL 기반 cross-asset VRP 예측이라는 새로운 위치를 점유한다.

III. 데이터 및 변수 구성

3.1 자산 유니버스(분석 대상) 및 선정 근거

본 연구는 주식(Equity), 채권(Bond), 원자재(Commodity)로 구성된 3개 자산군에서 총 11개 ETF를 분석 대상으로 사용한다. 구체적인 티커는 다음과 같다.

Equity(5): SPY, QQQ, IWM, EFA, EEM

Bond(3): TLT, IEF, AGG

Commodity(3): GLD, SLV, USO

자산 선정 기준은 다음과 같다. 첫째, 주식채권·원자재를 함께 포함하여 cross-asset VRP 예측 프레임워크가 특정 시장에 국한되지 않고 작동하는지 확인하고자 하였다. 둘째, 각 자산군에서 대표성과 유동성이 높은 ETF를 선택하여 데이터 품질과 재현 가능성을 확보하였다. 예를 들어 주식은 미국 대형주(SPY), 기술주(QQQ), 소형주(IWM), 선진국(EFA), 신흥국(EEM)으로 스타일/지역 분산을 확보하며, 채권은 장기(TLT)-중기(IEF)-종합(AGG)으로 듀레이션 스펙트럼을 커버한다. 셋째, 2010년 1월 이후 장기간 일별 OHLCV가 안정적으로 존재하는 자산만 포함하였다. 마지막으로 USO는 WTI 선물 기반 ETF로 롤오

메모 포함[26]: 인용

메모 포함[30]: 데이터 세트로 수정 필요

메모 포함[31]: 자산 유니버스로 수정 필요

메모 포함[27]: 위의 피드백과 같음. 마지막에 한 번에 정리하는게 어떨지

메모 포함[28]: 앞의 본 연구는~ 부분을 여기서 한번에 정리

메모 포함[32]: 표로 수정

메모 포함[33]: 해당 2010년 1월 이후인 이유가 있다면 추가 필요, 안정적으로 존재한다는 정확한 정의가 어떻게 되는 지 추가 서술 필요

메모 포함[29]: 인용 방법을 전체적으로 맞춰야함

8 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

버 구조의 영향(콘탱고/백워데이션)이 포함될 수 있으므로, 본 연구에서 USO의 변동성은 해당 구조가 지 포함한 투자자 관점의 실현 변동성으로 해석한다.

3.2 데이터 기간, 출처 및 전처리

분석에 사용한 데이터의 기간은 2010년 1월 ~ 2025년 1월 (약 15년, 약 3,780 거래일)을 사용했으며, 출처는 Yahoo Finance (yfinance API)에서 수집한 일별 OHLCV(Open, High, Low, Close, Volume)이다.

본 연구에서 사용하는 OHLCV 데이터는 각 거래일의 시가(Open), 고가(High), 저가(Low), 종가(Close), 거래량(Volume)의 5개 항목으로 구성된다. 종가(Close)는 로그수익률 계산과 HAR 기반 실현분산(RV) 추정의 기반이 되며, 고가저가시가 조합(OHLC)은 Parkinson, Garman-Klass, Rogers-Satchell 등 range 기반 변동성 추정량을 산출하는 데 활용된다. 이들 추정량은 종가 기반 추정 대비 이론적 효율이 5.0~7.4배에 달하며(Appendix 표 A-3 참조), 고빈도 데이터 없이도 일중 가격 변동 정보를 포착할 수 있다는 장점이 있다. Volume은 Amihud 비유동성 비율, Kyle Lambda, 거래량 서프라이즈 등 유동성 관련 피처의 원천 변수로 사용된다.

선행연구에서 실현분산 예측에 주로 사용되는 데이터는 고빈도(intraday) 틱 데이터 또는 5분 간격 수익률이다. 예를 들어 Andersen, Bollerslev, Diebold, Labys(2003)는 5분 수익률로 일별 RV를 구성하였고,

Christensen, Siggaard, Veliyev(2023)는 고빈도 RV와 점프 분리 기법을 바탕으로 기계학습 예측 모델을 구축하였다. 그러나 고빈도 데이터는 구독 비용이 높고, 채권·원자재 등 비주식 자산에 대해서는 장기간 데이터 확보가 어렵다는 실무적 한계가 있다. 본 연구는 'Yahoo Finance'에서 무료로 수집 가능한 일별 OHLCV만을 사용하면서도, range 기반 추정량을 통해 고빈도 환경의 정보 효율을 근사함으로써, 선행 연구의 고빈도 기반 최고 성능(Christensen+ 2023, 폴링 R^2 0.770)을 상회하는 결과(WENS 0.803)를 달성하였다. 다만, OHLCV 기반 접근은 일중 점프(jump)와 연속 변동(continuous variation)의 분리가 불가능하다는 한계를 가지며, 이는 5.4절의 향후 과제에서 논의한다.

수익률 및 가격 조정(배당/분할) 처리 일별 수익률은 로그수익률로 정의한다.
$$r_t = \ln(P_t / P_{t-1})$$

여기서 P_t 는 yfinance에서 제공하는 수정 종가(배당/분할 반영 Close)를 사용한다.

본 연구는 또한 OHLC를 이용한 range 기반 변동성 추정량을 사용한다. 이때 OHLC는 수정된 형태로 제공되지 않는 경우가 많아 원시 OHLC를 사용하며, 배당/분배로 인한 가격 점프가 range 추정량에 미치는 영향이 제한적임을 정량적으로 점검하였다. 구체적으로 11개 ETF 전체에서 배당락 후보일(시가 갭 > 0.5%)은 전체 거래일의 약 15.9%를 차지하며, 배당락일의 일중 범위(log(H/L))는 정상일 대비 평균 1.27배로 소폭 상승한다. 그러나 22거래일 롤링 윈도우에서는 단일 관측치의 비중이 1/22 ≈ 4.5%에 불과하

메모 포함[34]: 콘탱고, 백워데이션 등 용어에 대한 설명이 없어 문장의 이해가 다소 어려움. 해당 용어에 대한 간단한 설명을 보완하고, 이를 바탕으로 USO의 변동성을 투자자 관점의 실현 변동성으로 해석하는 이유를 보다 명확히 제시할 필요가 있음.

메모 포함[38]: 데이터 파트에서 나오는 건 어색함 4장에서 제시

메모 포함[35]: 데이터 전처리로 수정

메모 포함[36]: 데이터 기간은 2010년 1월 ~ 2025년 1월과 같은 범위 표기보다는 2010년 1월 ○일부터 2025년 1월 ○일까지와 같이 시작일과 종료일을 명확히 제시하는 방식으로 수정하는 것이 필요함.

메모 포함[39]: 식은 따로 빼는 걸 권장

메모 포함[40]: 수정된 형태에 대한 설명 필요

메모 포함[37]: 한국어로 설명 가능한 용어는 한국어 용어로 수정 필요

메모 포함[41]: 용어 설명 필요

메모 포함[42]: 식 수정 필요?

9 Weighted Ensemble를 활용한다. 증 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

다. 따라서 배당락으로 인한 점프가 윈도우 기반 추
정량에 미치는 전반적인 영향은 제한적일 것으로 판
단한다.

거래일 불일치로 인해 일부 자산에서 1~2일 수준
의 결측치 발생할 수 있다. 본 연구는 이러한 결측에
대해 전방 채움(forward-fill)을 적용한다. 전방 채움은
해당 구간의 수익률을 0으로 만드는 효과가 있어 단
기 RV/Range 추정량을 약간 축소할 수 있으나, 22거
래일 윈도우 기준 영향은 제한적임을 확인하였다.
또한 전방 채움을 제거한 경우 R^2 가 0.782에서
0.795로 소폭 상승하여, 전방 채움이 결과를 과대평
가하지 않는다는 강건성 결과를 보고한다.

3.3 예측 지평(horizon) 설정(모두 거래일 기준)

본 연구는 예측 지평 h 를 모두 거래일(trading days)
기준으로 정의하며,

$h \in 1, 5, 22, 60, 90, 120, 180, 252$ 로 설정한다. 이는
1~5거래일(일별 주간 위험관리), 22거래일(월간), 60~90
거래일(분기 전후), 120~180거래일(반기), 252거래일
(연간) 등 다양한 의사결정 지평을 포괄하기 위함이다.
또한 연율화 계수로 252를 사용하므로, 지평을
거래일로 두는 것이 자연스럽다.

3.4 실현분산(RV) 구성

실현분산 $RV_{i,t}(h)$ 는 자산 i 의 시점 t 이후 향후 h
거래일 구간 $[t + 1, t + h]$ 에서 실현된 수익률 제공의

평균을 연율화하여 구성한다.

$$RV_{i,t}(h) = \text{mean}(r_{[t+1:t+h]}^2) \times 252$$

여기서 r_t 는 3.2절의 로그수익률이다.

실현분산은 일반적으로 강한 우편향(right-skewed
distribution)을 띠므로, 통계적 모델링의 안정성을 확
보하기 위해 타겟(target, 종속변수)에 로그 변환을 적
용한다.

$$\text{target}(t, h) = \log(RV_{i,t}(h)) = \log(\text{mean}(r_{[t+1:t+h]}^2) \times 252)$$

3.5 내재분산(IV) 구성과 변동성 지표

본 연구에서 내재분산 $IV_t(h)$ 는 "자산별 옵션을
직접 수집한 내재분산"이 아니라, 시장의 공통 불확
실성/위험회피 수준을 대표하는 글로벌 변동성 지표
기반 proxy로 구성한다. 기본적으로 CBOE VIX를 사
용하며, VIX 포인트를 소수로 변환한 뒤 제공하여
연율화 분산 단위로 변환한다.

$$IV_t(h) = (VIX_t / 100)^2$$

VIX 자체뿐 아니라 기간구조 정보를 피쳐로 포함
하기 위해 CBOE에서 제공하는 VIX9D, VIX3M을 함
게 사용한다. 각 지표의 만기와 표본 내 가용 기간은
다음과 같다.

VIX: 30 캘린더일(약 22거래일),

VIX3M: 93 캘린더일(약 63~64거래일),

VIX9D: 9 캘린더일(약 6~7거래일),

VIX3M의 경우 93 캘린더일은 거래일 기준으로
약 63일 남짓에 해당하므로, 본 연구의 60거래일 예
측 지평과 매칭할 때 근사(approximation)된 기간구조

메모 포함[43]: 전방 채움(forward fill)의 장점을 기반으로 결
측치 처리에서 어떠한 효과를 보이는지 서술하는 방식으로
문장을 보완할 필요가 있음. 예를 들어 "전방 채움의 ~한 장
점으로 인해 결측치 처리에서 ~한 효과를 보인다"와 같은 형
태로 설명하는 것이 적절함. 또한 다른 결측치 처리 방법과의
비교가 존재한다면 해당 내용을 함께 제시하는 것이 필요함.

메모 포함[44]: 해당 문장은 "-하는 것이 자연스럽다"와 같
은 표현으로 인해 대화체에 가까운 서술로 보임. 학술 논문에
적합한 서술형 문장으로 수정하는 것이 필요함. 전체적으로
이런 대화체 문장이 많음 확인 후 수정 필요.

10 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측 지표로 사용된다.

VIX9D는 2011년에 도입되어 2010년 구간에 걸쳐 이 존재한다. 본 연구는 예측 기간에서 인위적인 기 울기 신호가 생기지 않도록, 해당 기간의 VIX9D 수 준을 VIX로 대체(VIX9D $\approx$ VIX)한다. 따라서 VIX9D/VIX 비율 피쳐(VIX9D 기술기)는 예측 기간 에서 1로 설정하여("9D=30D" 가정), 0 대입으로 발생 할 수 있는 비현실적 급락 신호를 방지한다.

이 처리 방식의 강건성을 확인하기 위해, (i) 전체 기간(2010~, VIX 대체) vs (ii) 2011년 이후(결측 없음) vs (iii) VIX9D 피쳐 미사용의 22d 예측 성능을 비교 하였다.

표 4. VIX 피쳐별 22d 예측 성능

Config	Period	VIX9D Treatment	R ² (22d)
(i) Full period, VIX substi	tute 2010~	VIX9D = V	0.748
(ii) 2011 only 20	11~ Ac	tual VIX9D	0.766
(iii) VIX9D excluded	2010~	Excluded	0.754

3.6 VRP 타겟 산출(2단계 구성)

본 연구의 VRP는 연율화 분산 단위로 다음과 같 이 정의한다.

$$VRP_{i,t}(h) = IV_{i,t}^2 - RV_{i,t}(h)$$

즉, 내재분산(위험중립 기대분산 proxy)에서 실현 분산을 뺀 값이다.

최종 예측 대상은 VRP이지만, 직접적으로 VRP를 학습시키기보다 (1) 전방 실현분산 RV_{hat} 을 예측하 고, (2) 관측된 IV^2 와 결합하여 VRP $_{hat}$ 를 산출하는 2단계 접근을 취한다.

$$VRP_{hat_{i,t}}(h) = IV_{i,t}^2 - RV_{hat_{i,t}}(h)$$

이 설계는 피쳐($t-1$ 이전 정보)와 타겟($t+1$ ~ $t+h$) 구간) 간 중첩을 방지하기 위한 목적을 가진다.

VIX는 약 30일(대략 22거래일)에 대응하는 기대 변동성을 반영하므로, 이를 모든 지평(1~252거래일) 의 IV proxy로 사용할 경우 만기 불일치(maturity mismatch)가 존재할 수 있다. 본 연구는 자산별 옵션 기반 IV를 직접 구성하지 않고, 시장 전체의 불확실 성-위험회피 수준을 반영하는 공통 변동성 위험 레짐

(common-volatility-risk-regime)의 proxy로서, $IV_{i,t}^2 \approx (VIX_t/100)^2$ 를 사용한다. 즉, 본 연구에서는 $IV_{i,t}^2$ 를 "지평 h 에 정확히 대응하는 개별 자산의 만기 IV^2 "로 간주하는 대신, 다중 자산에 시장 공통적으로 적용 가능한 변동성 위험 가격(Price of volatility risk) 지표로 넓히 해석한다. 만기 불일치의 실질적 영향을 정량적으로 확인하 기 위해, 각 지평에서 (i) VIX 단독, (ii) VIX9D로 대체 (9D), (iii) VIX3M으로 대체(3M), (iv) IV 지표를 동시 투입한 경우의 예측 성능(R^2)을 비교하였다.

표5. 지평별 R² 예측 성능

	VIX Only R ²	VIX9D Subst R ²	VIX3M Subst R ²	All IV R ²
1d	0.108	0.112	0.108	0.112

메모 포함[46]: 중첩을 방지하기 위한 목적으로 2단계 접근을 취한다고 되어 있는데 설계 이유를 좀 더 명확 하게 적는게 좋을 것 같음

메모 포함[45]: 표가 페이지에서 분할되지 않고 한 페이지 내에 포함되도록 편집을 수정할 필요가 있음. 또한 논문의 편집 및 레이아웃 구성은 저자가 직접 확인하고 조정하는 것이 필요함.

그리고 표의 형식이 해당 논문에서 요청한 형식과 다른 부분 이 있는 것 같으니 확인 필요(한국정보기술학회저널) 검색해 서 서식 받아서 확인

11 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

		(+0.005)	(-0.000)	(+0.005)
5d	0.591	0.604 (+0.013)	0.587 (-0.004)	0.607 (+0.016)
22d	0.769	0.766 (- 0.003)	0.763 (-0.006)	0.767 (- 0.001)
60d	0.77	0.766 (- 0.004)	0.767 (-0.003)	0.762 (- 0.007)
90d	0.755	0.748 (- 0.006)	0.754 (-0.001)	0.743 (- 0.012)
120d	0.744	0.737 (- 0.007)	0.740 (-0.004)	0.726 (- 0.018)
180d	0.717	0.714 (- 0.002)	0.700 (-0.016)	0.684 (- 0.032)
252d	0.675	0.677 (+0.001)	0.642 (-0.033)	0.613 (- 0.063)

으므로 학습/평가에서 제외된다.

또한 예측 지평이 긴 경우 타겟 윈도우가 겹치면
서 검증 누출 가능성이 커질 수 있으므로, 학습/테스
트 분할 경계와 교차검증 폴드 경계에 예측 지평 h
만큼의 정화 구간을 두어 타겟 윈도우 중첩을 완화
한다.

3.8 예측 파이프라인 및 방법론

본 연구의 최종 목표는 3.6절에서 정의한 VRP를
예측하는 것이며, 3.6.2절의 2단계 구조(RV_hat 예측
후 VRP_hat 산출)를 따른다. 모델의 직접 타겟은 분
포 안정화를 위해 $\log(RV_i,t(h))$ 로 둔다.

원자재는 주식 기반 VIX와 다른 구조를 가질 수
있으므로, 금과 원유에 대해 CBOE의 자산특화 변동
성 지표(GVZ, OVX)를 대체 적용하는 강건성 검증을
수행하였다. 그 결과 GLD는 +2.6%p, USO는 +0.8%p
로 개별 자산에서는 개선이 관측되었으나, 전체 성
능 변화는 -0.8%p로 제한적이어서 단일 VIX 기반
proxy 사용의 타당성이 유지된다.

3.7 최종 패널 데이터 구성

본 연구의 데이터는 "날짜 x 자산" 패널 형태로
구성된다. 각 날짜 t에서 피처(feature, 설명변수)는 t -
1까지의 정보로 계산하고, 타겟은 [t + 1, t + h] 구간에
서 계산된 전방 실현분산(로그)이다. 따라서 각 지평
h에 대해 표본의 끝부분 h일은 타겟을 계산할 수 없

3.9 피처(Features) 구성 및 전처리

피처는 (i) HAR 기반 래그, (ii) OHLC range 기반 변
동성 추정량(HF proxy), (iii) IV 기간구조/VRP 통계(IV
surface), (iv) 대안 데이터(alternative data; 거래량 기반
피처)로 구성된 다중 그룹을 사용한다(총 37개 피처).
모델 간 비교에서는 동일 피처 세트 조건을 유지하
여 공정성을 확보한다.

또한 피처 스케일 차이를 줄이기 위해 표준화(예:
StandardScaler)를 적용하며, 스케일링 파라미터는 학
습 구간에서만 추정하여 테스트 구간으로 정보가 누
출되지 않도록 한다. 해당 구현 원칙은 학습/검증 절
차에서 일관되게 적용된다.

3.10 학습 및 검증 절차

12 Weighted Ensemble를 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

시계열 데이터의 시간적 선후 관계를 엄격히 보존하기 위해 전체 표본을 날짜순으로 정렬한 뒤, 전반부 80%를 모델 학습(Train)에, 후반부 20%를 성과 평가(Test)에 배정(out-of-sample)한다.

전방 타겟은 $[t + 1, t + h]$ 구간을 사용하므로, 인접 관측치 간 타겟 윈도우 중첩(overlap)이 필연적으로 존재한다. 이는 모델 검증 시 "미래 타겟 중첩에 따른 정보 누출(data leakage)"과 예측 오차의 강한 자기상관을 유발할 수 있다. 본 연구는 이를 방지 및 완화하기 위해 학습 데이터와 테스트 데이터 분할 경계선에 정화 구간(purge gap) = h 를 적용하고 5-fold TimeSeriesSplit(확장 윈도우)을 사용한다. 또한 유의성 검정에서는 지평별로 HAC(bandwidth= h)를 사용하여 오차 서열간 자기상관 편향을 보정한다.

3.11 모델 구성(Models)

본 연구는 해석 용이성과 일반화 성능을 함께 보기 위해 선형·트리·딥러닝 모델을 포함한다. 주요 비교군은 다음과 같다.

선형: Ridge, Lasso, ElasticNet

트리 기반: Random Forest, XGBoost, LightGBM

딥러닝(시계열): Bi-LSTM + Temporal Attention (BiLSTM-A)

실험 결과에서는 1~22d 구간에서 선형 계열이 강하고, 60~90d에서 LSTM(소수 range 피쳐)이 강하며, 180~252d에서 RF가 강한 양상이 관측된다.

3.12 하이퍼파라미터 설정

Ridge는 다중공선성이 큰 피쳐(특히 range 계열)에서 안정적인 추정을 위해 사용한다. 본 연구는 자산군 간 이질성을 반영하기 위해 자산군별로 서로 다른 α 를 고정한다.

또한 Ridge의 규제 강도에 대한 민감도 분석으로 $\alpha \in [0.001, 5000]$ 범위에서 성능이 큰 폭으로 흔들리지 않음을 확인했다.

ElasticNet은 L1(피쳐 선택)과 L2(다중공선성 완화)를 결합하여 확장 피쳐(59개) 환경에서 과적합을 줄이기 위한 모델로 포함되며, 22d에서 성능 개선이 보고되었다. 최적 파라미터는 $\alpha=0.01$, $l1_ratio=0.1$ (Ridge 성적 90%+LASSO 성적 10%)이다.

BiLSTM-A(Bi-LSTM + Temporal Attention)는 37개 전체 피쳐 대신 3개 주요 range 피쳐(RS, GK, RC)만 입력으로 사용하며, 입력 시퀀스 길이는 22(거래일)이다. 과적합 방지를 위해 모델의 은닉층 크기, 학습률, 드롭아웃 등 상세 하이퍼파라미터 탐색 범위와 5개 시드를 이용한 재현성 확보 절차는 아래의 표6과 같다.

표6. BiLSTM-A 하이퍼파라미터

Parameter	Optimal	Search Range
hidden_dim (d_h)	32	64, 128
learning_rate (eta)	0.001	0.001, 0.001, 0.01
dropout(p)	0.0	0.0, 0.3, 0.5
seq_len(L)	22** {1	0, 22, 44

메모 포함[47]: 4장에 가야하는 내용 같음

13 Weighted Ensemble를 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

batch_size	64	고정
epochs	20	고정
optimizer	Adam	Fixed
loss	MSE	Fixed
Input features	3	RS, GK, RC

22d 지평에서는 Ridge와 XGBoost를 결합한 가중 앙상블을 사용한다. 가중치는 Ridge 70%, XGBoost 30%로 고정한다.

$$y_{\text{hat}} = 0.7y_{\text{hat_Ridge}} + 0.3y_{\text{hat_XGB}}$$

WEEns 앙상블 구조는 다음과 같다. 11개 자산의 OHLCV와 변동성 지표로부터 37개 피처를 구성한 뒤, 자산군별(Equity $\alpha=100$, Bond/Commodity $\alpha=10$)로 분리된 Ridge 모델의 예측(70%)과 전체 자산 통합 XGBoost 예측(30%)을 가중 결합하여 최종 RV_{hat} 를 산출한다.

Random Forest / XGBoost / LightGBM은 37개 피처 기반 비교군으로 포함되어, 지평별 성능을 비교한다. 구체적인 하이퍼파라미터 값은 부록 표(Appendix)에 기재한다.

3.13 평가 지표 및 통계적 검정

평가지표는 중위 R^2 를 1순위, 풀링 R^2 를 보조 지표로 보고한다(풀링 R^2 는 자산 간 스케일 차이의 영향을 받을 수 있음).

모델 간 차이의 통계적 유의성은 Diebold-Mariano(DM) 검정으로 평가한다. 예측 타겟이 일정

기간($t+1, t+h$)의 평균으로 구성되어 인접한 날짜 간에 타겟 윈도우가 필연적으로 겹치므로, 예측오차 간에 최대 $h-1$ 차 자기상관이 존재한다. 이에 따라 DM 검정에서는 지평 h 를 Newey-West HAC 대역폭(bandwidth)으로 사용하여 중첩 구조에 의한 분산 과소추정을 보정한다. 장기 지평($h \geq 120$)에서는 점근 근사의 한계를 보완하기 위해 블록 부트스트랩(block size= h , $B=5,000$)을 보조 검정으로 사용하여 유의성을 재확인한다.

표7. WEEns 앙상블의 지평별 성능

h	Ridge(37)	BiLSTM-A(3)	HAR-3(3)	LASSO(37)	RF(37)	Champion
1d	0.114	0.092	0.109	0.116	0.113	LASSO
5d	0.625	0.577	0.581	0.625	0.611	Ridge
22d	0.798	0.78	0.761	0.79	0.77	Ridge
60d	0.774	0.796	0.784	0.782	0.752	BiLSTM-A
90d	0.752	0.788	0.781	0.763	0.737	BiLSTM-A
120d	0.737	0.751	0.758	0.748	0.73	HAR-3
180d	0.691	0.708	0.705	0.707	0.719	RF
252d	0.516	0.589	0.611	0.555	0.705	RF

IV. 실험 결과

4.1 실험 개요

본 연구는 11개 ETF 패널 자료를 대상으로, 8개 예측 지평(표 1 참조)에서 3.6.2절의 2단계 구조에 따라 전방 실현분산을 예측하고, 내재분산 대응치와 결합해 $VRP_{\text{hat},i,t}(h) = IV_{t^*}^2 - RV_{\text{hat},i,t}(h)$ 를 산출한다.

메모 포함[48]: 왜 해당 가중치로 고정했는지에 대한 설명 필요

메모 포함[49]: 4장에 들어가야하는 내용

메모 포함[50]: 4. 실험 결과 이후에 4.1 실험 개요가 배치된 현재의 구성은 논문의 일반적인 구조와 다소 맞지 않아 보임. 실험 개요는 실험 결과 이전에 배치하여 실험 설정 및 평가 방법을 먼저 설명하는 형태로 수정할 필요가 있음.

14 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

본 연구에서 예측 시점의 내재분산 대응치(IV_t^2) 60-90d에서 BiLSTM-A이 우위, 180-252d에서 RF/HAR-3가 우위를 보이는 교차 패턴이 뚜렷이 관측된다.

이미 관측된 값이므로, VRP 예측 오차는 RV 예측 오차와 부호만 반대이고 기계적으로 절대적 크기가 동일하다. 따라서 모델 간 우열 비교와 선택은 1단계 RV 예측 성능 비교로 일관되게 수행할 수 있다.

성능 지표는 횡단면 변동의 영향을 배제한 순수 시계열 예측력을 보기 위해 중위 R^2 (자산별 R^2 중 위값)를 1순위로, 풀링 R^2 를 보조 지표로 보고한다.

4.2 지평별 대표 모델 요약

지평별로 가장 높은 성능을 보인 모델은 다음과 같이 요약된다. 1-22d 구간에서는 ElasticNet-59(풀링 R^2 0.807), 60-90d에서는 BiLSTM-A(3 range 피쳐, 풀링 R^2 0.796), 120d에서는 HAR-3(0.758), 180-252d에서는 Random Forest(각각 0.719, 0.705)가 가장 높은 풀링 R^2 를 기록하였다. 이처럼 예측 지평이 바뀌면 유리한 모델 구조가 달라지는 패턴이 관측된다.

1-22d 구간에서는 피쳐가 많을수록(특히 range/기간구조/거래량 포함) 선형 결합과 앙상블 모델이 가장 우수하였다. 반면 60-90d 지평에서는 37개 전체 피쳐 대신 3개의 핵심 range 피쳐만 압축적으로 채택한 LSTM 모델이 오히려 가장 우수한 예측력을 보였다(60d 풀링 R^2 0.796). 더 길어진 180-252d 지평에서는 트리 구조 알고리즘인 Random Forest가 가장 높은 풀링 R^2 를 기록하는 이질적인 결과를 확인하였다.

표 7는 주요 모델의 지평별 풀링 R^2 를 종합적으로 비교한 것이다. 1-22d에서 WEns Ridge가 우위,

표 8. 지평별 챔피언 모델의 중위 R^2

h	Best Model (Type)	Pooled R^2	Median R^2
1d	LASSO(Linear)	0.116	0.019 (WEns)
5d	Ridge(Linear)	0.621	0.203 (WEns)
22d	ElasticNet-59/WEns (Linear/Ensemble)	0.807/0.803	0.097/0.215
60d	BiLSTM-A (DL)	0.796	0.15
180d	RF (Tree)	0.719	-0.456
252d	RF (Tree)	0.705	-0.482

4.3 22거래일 지평에서의 주요 결과

22거래일 예측에서 대표적인 최고 성능 모델은 WEns(Ridge 70% + XGBoost 30% 가중 앙상블, 37피쳐)이며, 풀링 R^2 0.803, 중위 R^2 0.215를 기록하였다.

h	Pooled R^2	RMSE	MAE	QLIKE	Median R^2
1d	0.1171	2.492	1.7489	3.4463	0.0238
5d	0.6265	0.7464	0.5891	0.3203	0.1825
22d	0.797	0.4677	0.3753	0.1279	0.1753
60d	0.7924	0.4521	0.3548	0.1246	-0.035
90d	0.7756	0.4626	0.3668	0.1311	-0.373
120d	0.7586	0.4744	0.3788	0.1394	-0.7204
180d	0.7476	0.4778	0.3808	0.1421	-0.9055

메모 포함[51]: 표8에 대한 언급?

15 Weighted Ensemble를 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

252d 0.7077 0.5065 0.4078 0.1633 2.1804
표 9. WEns 앙상블의 지평별 성능

표 9에 나타나듯, WEns 앙상블은 22거래일(월간) 지평에서 최적의 예측력을 보이지만, 60거래일(분기) 이상으로 지평이 확장될 경우 시계열 설명력을 엄밀히 대변하는 중위 R²가 음수(-) 영역으로 진입한다. 이는 단일 풀링(pooling) 모델이 180-252d 지평에서 각 자산군이 갖는 독자적인 변동성 구조를 동시에 모두 적합(fit)시키는 데 한계가 있음을 시사한다.

장기 지평에서 중위 R²가 음수로 전환되는 현상은 (1) Equity/Bond/Commodity 간 변동성 동학 이질성으로 인해 단일 풀링 모델이 모든 자산 패턴을 동시에 포착하기 어렵고, (2) 지평이 길어질수록 조건부 모델의 상대적 우위가 감소하여 비조건부 평균이 더 강한 예측기가 되는 SNR 감소를 반영한다. 180-252d 예측에서는 자산군별 적용 전략이 필요함을 시사한다.

자산군별 252d 중위 R²를 분해하면, Equity(5종) -1.82, Bond(3종) -4.31, Commodity(3종) -5.64로 채권과 원자재가 주식 대비 훨씬 낮다. 이 중 Equity 내에서 도 SPY:QQQ는 양수를 유지하나 EEM:EFA는 큰 음수를 기록한다.

채권과 원자재 자산군은 180-252d 이상 지평에서 눈에 띄게 더 낮은 R² 성과를 보인다. 주식과 뚜렷이 구별되는 채권의 듀레이션 리스크 분포, 그리고 원자재의 콘탱고/백위데이션 구조 차이 등이 단일

표 10은 WEns 앙상블의 22거래일 지평에서 11개 ETF 각각의 개별 R²를 보고한다. 풀링 R²(0.803)는 자산 간 수준 차이(횡단면 변동)를 포함하므로 높은 값을 보이지만, 개별 자산 R²는 순수 시계열 예측 정확도를 반영하여 상대적으로 낮다. 주식(Equity) 자산군, 특히 SPY와 QQQ가 가장 높은 개별 R²를 기록하였으며, 채권(Bond)은 예측 난이도가 높은 것으로 나타났다.

표10. WEns 앙상블 자산별 성능(22d전방RV)				
Asset	Class	R ²	RMSE	Rating
SPY	Equity	0.299	0.379	Good
QQQ	Equity	0.262	0.437	Good
IWM	Equity	0.215	0.409	Fair
EFA	Equity	0.139	0.405	Fair
EEM	Equity	0.059	0.441	Fair
TLT	Bond	-0.003	0.568	Poor
IEF	Bond	0.03	0.523	Fair
AGG	Bond	0.019	0.481	Fair
GLD	Commodity	0.105	0.413	Fair
SLV	Commodity	0.119	0.475	Fair
USO	Commodity	-0.081	0.592	Poor
Pooled	All	0.803	0.468	Overall

개별 자산 R²와 풀링 R²의 큰 괴리는 모델의 예측력이 상당 부분 자산 간 횡단면 변동에 의존하고 있음을 시사하며, 이는 중위 R²를 1순위 지표로 사용하는 본 연구의 보고 방식의 타당성을 뒷받침한

메모 포함[52]: 앞에 표 8에 대한 언급이 안나왔는데 표 9가 먼저 나옴

16 Weighted Ensemble을 활용한다.중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측
다.

4.4 다중 모델 22d 비교

표11은 대표 8개 모델의 성능을 비교한 결과이다.
풀링 R² 기준으로는 선형 모델(Lasso/ElasticNet)이
상위권을 차지하며, 중위 R² 기준으로는 Random
Forest가 상대적으로 높게 나타난다. SVR, MLP는 중
위 R²가 크게 음수로 나타나 안정적 일반화가 어려
웠다.

Model	Type	Pooled R ²	Median R ²
Lasso	Linear	0.7712	0.0998
ElasticNet	Linear	0.7696	0.0742
Ridge(pooled)	Linear	0.7625	-0.0033
Ridge(per-class)	Linear	0.7618	-0.0049
RF	Tree	0.7590	0.1424
LightGBM	Tree	0.7387	0.0589
XGBoost	Tree	0.7330	0.0353
SVR	Kernel	0.6901	-0.0939
MLP	NN	0.6183	-0.2366

표 11. 다중 모델 22d 비교

이는 '기계학습 모델의 구조가 복잡할수록 시계열
예측 성능도 우상향할 것'이라는 통념과 배치된다.
변동성 예측 환경 특유의 (i) 강한 자기상관 구조, (ii)
높은 잡음, (iii) 국면(레짐) 변화가 공존하기 때문에,
적절한 규제를 부여한 선형 모델이 테스트 구간에서
예측의 분산을 제어하며 더 안정적인 성능을 보일
수 있다.

표 12는 본 연구에서 동일 데이터(11개 ETF,
2010~2025)-동일 37개 피쳐-동일 검증 절차(80:20

temporal split, purge=h)를 적용하여 수행한 공정 비교
결과이다. 이 표의 모든 수치는 동일 조건에서 산출
되었으므로 직접적인 모델 간 우열 비교가 가능하
다.

BiLSTM-A는 과적합 방지를 위해 의도적으로 3개
range 피쳐만 사용하며(4.4.2절 참조), ElasticNet-59는
37개 기본 피쳐에 22개 cross-lag 피쳐를 추가한 확장
세트를 사용한다. 피쳐 수 차이는 불공정 비교가 아
닌 각 모델의 최적 설계를 반영한 것이다.

표 12의 모델은 두 Median R² 갖는다. 첫째,
합친 단면 데이터 없이 공인된 CV와 VIX 기간구
조만으로 문헌에서 보고된 최고 수준의 성능(표 12
참조)에 필적하거나 이를 상회하였다. 특히, 본 프레
임워크와 동일 조건에서 평가된 전통적 시계열 모델
인 GARCH(1,1) 및 GJR-GARCH 22d 풀링 R² ? 0.69)
보다, 기본 선형 구조(HAR(3, 0.761))와 기계학습/정규
화 이상불(WEns, 0.803)이 예측 성능을 대폭 상회합
을 입증하였다. 둘째, 단일 자산(S&P 500)이 아닌 주
지체권/원자재 11개 ETF를 통합한 cross-asset 환경에
서 일관되게 검증되었다.

Model	Type	#Feat	Features	Pooled R ²	Median R ²	RMSE	Note
GARCH(1,1)	TS	—	Daily log returns	0.6939	0.0273	0.5782	Tradition al benchmark
GJR-GARCH	TS	—	Asymmet ric returns	0.6989	-0.0066	0.5735	Asymmet ry effect

17 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

HAR-3	Linear	3	RV lags	공정 비교 실험을 수행하였다. 그 결과, Base-32 지평에서 풀링 R ² 가 기준 대비 높은 것으로 나타났다. 0.761 0.1709 0.5415 Benchmark
Ridge (pooled)	Linear	37	Full	이 산출되었다. 더불어 다수 개별 자산에, SPY - Single 0.7625 -0.003 0.5093
Ridge (per-class)	Linear	37	Full	0.18, QQQ -0.81) 단위에서 딥러닝 예측 결과, Per-class 0.7618 0.0949 0.5101
Lasso	Linear	37	Full	0.7712 0.0998 0.4999 L1 reg.
ElasticNet	Linear	37	Full	하는 강한 음수 순위 R ² 편향을 남겼다(상세 표는 부록 참조) 이는 다수 피처가 교차하는 차원의 저주 0.7696 0.0742 0.5017
RF	Tree	37	Full	0.759 0.1424 0.513 제약에서 복잡한 신경망 구조가 강한 과적합 함정에 0.733 0.0353 0.54
XGBoost	Tree	37	Full	빠진 전형적인 양상을 증빙한다. 종합하면, BiLSTM- 0.738 0.0589 0.5343
LightGBM	Tree	37	Full	A에 3개의 range 핵심 피처를 입력한 역사 결정이 0.738 0.0589 0.5343
SVR	Kernel	37	Full	0.7391으로 식(9)의 불공평한 축소"가 아니라 0.7391 0.0589 0.5343
MLP	NN	37	Full	0.6183 -0.3266 0.6457 딥러닝의 과적합 통계를 위해 채택했던 Overfitting 한 피처 설계 선택이었음이 확인된다. 나아가 본 예
BiLSTM-A	DL	3	Range (RS,GK,R C)	0.78 환경하에서 55% 조건적(61.4%) 증 3-feat 단순 0.2355 0.4767
WEns	Ensemble	37	Full	복잡성 증가보다 사전 피처 선택과 안정적 정규화 계열 구성에 시계열 예측성에 더 핵심임을 관찰하였 0.803 0.215 0.468 Ridge 70%+XG B 30%
ElasticNet-59	Linear	59	Extended feat.	0.807 피처 기여 분석 0.4591 Best pooled

표 12. 본 연구 내 공정 비교

가장 높은 성능을 낸 선형 모델(WEns) 군은 37개 구조의 전체 피처 집합을 사용한 반면, BiLSTM-A 모델은 3개의 range 피처에 국한된 설계값을 주었다는 부분에서 "선형 모델(37피처) 대 딥러닝(3변수)"이라는 불공정 비교(unfair comparison) 가능성이 제기될 수 있다. 이를 검증하고자 BiLSTM-A 모델에도 37피처의 전체 피처를 동일하게 적용하여 재학습시키는

피처 그룹이 실제로 예측력에 기여하는지 확인하기 위해 서브셋 실험을 수행하였다. 그 결과, HAR+Range(8피처) 조합이 풀링 R²와 중위 R² 모두에서 강한 성능을 보였고, 단순히 피처를 많이 넣는다고 성능이 항상 증가하지는 않았다.

표 13. WEns 모델 피처 서브셋

Subset	Feat	R ²	R ²
--------	------	----------------	----------------

18 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

	Pooled	Median	
HAR + Range	8	0.7854	0.1480
Range only	5	0.7722	0.0938
Full(37)	37	0.7618	0.0949
HAR only	3	0.7321	0.1678

[이 결과는 1~22d 구간에서 WEns(37피쳐 앙상블)이 풀링 $R^2 = 0.803$ 으로 가장 높은 성능을 기록한 사실과 모순되지 않는다. 즉, 기본 선형 구조에서는 HAR+Range만으로도 충분히 강하지만, 고변동성 국면이나 22d 지평에서는 IV Surface/Alt Data를 포함한 다수 피쳐 결합과 앙상블이 추가 개선을 제공할 수 있다.

단일 방법의 편향을 방지하기 위해 7개 방법론(Ridge 정규화 계수, Permutation, XGBoost Gain, SHAP, Mutual Info, Spearman, RFE)의 중요도를 평균하여 표 14의 합의 순위를 산출하였다.

Rank	Feature	Group	Mean Rank
1	RogersSatchell_22	HF Proxy	2.6
2	Garch_Weekly	GARCH	4.4
3	Parkinson_22	HF Proxy	5.1
4	GarmanKlass_22	HF Proxy	5.3
5	Garch_Daily	GARCH	6.7
6	LogRV_lag22	HAR	7.6
7	LogRV_lag1	HAR	9.1
8	Parkinson_5	HF Proxy	9.1
9	IV_VRP_ma22	IV Surface	11.7

10	IV_VIX	IV Surface	11.9
----	--------	------------	------

표 14. 피쳐 중요도(7개 방법 평균)
HF Proxy(range 기반) 피쳐가 상위 4위 중 3개를 차지하며, GARCH 피쳐가 그 다음으로 높은 순위를 기록하였다. IV Surface 피쳐는 상대적으로 낮은 순위이지만, 4.6월의 레짐 분석에서 High VIX 구간의 추가 기여가 두드러지는 조건부 중요성을 보인다.

4.6 고변동성 분석

VIX 분위수 기반 레짐 분석 결과, HAR-3 대비 WEns의 개선 폭은 VIX 레짐에 따라 뚜렷이 달라졌다. Low VIX(하위 50%): R^2 0.739 $\rightarrow$ 0.781(+0.042), Mid VIX(50~90%): 0.698 $\rightarrow$ 0.722(+0.024)에 그친 반면, High VIX(상위 10%) 구간에서는 0.602 $\rightarrow$ 0.765(+0.163)으로 개선 폭이 가장 컸다.

이는 (i) IV Surface(기간구조, VRP 통계) 피쳐가 극단적 불확실성에서 추가 정보를 제공하고, (ii) HF proxy(range 계열)가 위기 시 확대되는 일중 변동을 포착하기 때문으로 해석할 수 있다.

이와 함께, 자산 클래스 및 모델 비교 기간(서브샘플)에 따른 이질성 분석 결과는 모형 개선의 양면성을 보여준다. HAR-3 대비 WEns의 성능의 대폭 향상은 주로 주식(Equity) 패널에서 R^2 +0.163 개선으로 이끌었으나 원자재(Commodity)에서는 개선이 매우 둔화(-0.055)되는 양상을 띠었다. 또한, 2010-2014 기간에는 성능 향상이 뚜렷하나 2020년 코로나 이후 국면에서는 단일 피쳐 모델 간 성능 우위 차이가 줄

메모 포함[53]: 정확하게 어떤 기준에서 모순되지 않는지 불명확함

19 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측
어드는 경향이 관찰되었다. 이는 모델이 특정 시황 정을 확장한 결과, 축소 피쳐(9개) 기반 비교에서는
에 과적합되지 않도록 향후 자산 군집 별 또는 레짐 예측 오차의 분산 축소 효과가 크지 않아 비교적 유
별 적용형 최적화(regularization) 적용의 당위성을 제 의하지 않았으나, 다수 피쳐(37) 결합 앙상블은 매우
공한다. 높은 신뢰도(1% 수준)로 기본 HAR 모형의 한계를 넘어섰다.

표 15. 자산군별 HAR-3 vs WEns 성능(22d R²)

Asset	Class	HAR-3 R ²	WEns R ²	Delta
SPY	Equity	0.136	0.299	0.163
QQQ	Equity	0.091	0.262	0.171
IWM	Equity	0.088	0.215	0.127
EFA	Equity	0.032	0.139	0.107
EEM	Equity	-0.015	0.059	0.074
TLT	Bond	0.015	-0.003	-0.018
IEF	Bond	0.022	0.03	0.008
AGG	Bond	0.01	0.019	0.009
GLD	Commo dity	0.075	0.105	0.03
SLV	Commo dity	0.174	0.119	-0.055
USO	Commo dity	-0.035	-0.081	-0.046

4.7 통계적 유의성 검정

22거래일 지평에서는 Newey-West
HAC(bandwidth=22)를 적용한 통계적 검정 결과,
WEns 가중 앙상블은 HAR-3 대비 Diebold-Mariano
통계량 -8.80 ($p < 0.001$)을 기록하며 극히 유의미하
게 우수하였다.

또한 지평별로 HAC bandwidth를 h로 두고 DM 검

Newey-West HAC 검정(bandwidth=h)에서 WEns vs
HAR-3의 DM 통계량은 22d -8.802($p < 0.001$), 60d -
7.481($p < 0.001$)이었으며, 블록 부트스트랩($B=5,000$)에
서도 각각 -8.756, -7.593(모두 $p < 0.001$)으로 두 방법
모두 동일한 결론을 지지하였다.

4.8 강건성 검증 요약

Commodity IV 대체(GVZ/OVX) 실험에서 GLD
+2.6%p, USO +0.8%p 개선이 있으나 전체 성능 변화
는 -0.8%p로 제한적이며, 단일 VIX proxy 사용의 타
당성이 확인되었다. 블록 부트스트랩 DM 검정(block
size=h, $B=5,000$)에서도 HAC 기반 DM 결과와 일치하
여 유의성이 재확인되었다.

잔차 진단에서 비정규성(Jarque-Bera $p < 0.001$), 자
기상관(Ljung-Box $p < 0.001$), ARCH 효과($p < 0.001$)가
관측되며, 이는 변동성 시계열의 일반적 특성으로
해석할 수 있다. 본 연구는 HAC 기반 검정과 블록
부트스트랩을 통해 이러한 특성이 통계적 비교에 미
치는 영향을 완화하였다.

4.9 연구 질문(RQ)에 대한 답변

본 장의 실험 결과를 종합하여, 서론에서 제기한

메모 포함[54]: 연구 질문(RQ)에 대한 답변과 같은 표현은
일반적인 논문 결론 구성 방식과는 다소 맞지 않아 보임. 결
론에서는 연구 결과 요약 및 시사점을 중심으로 서술하는 형
태로 수정하는 것이 필요함.

20 Weighted Ensemble를 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측 네 가지 연구 질문에 답한다.

RQ1 (공개 데이터 기반 VRP 예측 가능성). 11개 ETF(주식·채권·원자재) 패널에 대해 공개 OHLCV와 VIX 기간구조만을 이용한 VRP 예측이 가능함을 확인하였다. 22d 지평에서 폴링 R^2 0.803을 기록하였으며, HAR 모델 대비 유의미한 우위를 보였다.

RQ2 (지평별 성능·피쳐 변화). 단기에서는 HAR+Range(8피쳐) 기반 다중 피쳐 결합이, 중기에서는 소수의 range 피쳐가 핵심 역할을 하며, 극단적 변동성 구간에서는 IV Surface 정보의 기여가 상승한다.

RQ3 (모델 구조별 상대 성능). 예측 지평에 따라 최적 모델 구조가 달라져, 1~22d 구간은 정규화 선형 앙상블, 60~90d 구간은 시계열 신경망, 180~252d 구간은 트리 모델이 가장 유리하게 작용하였다.

RQ4 (예측의 경제적 실용성). SPY 대상 VRP 신호 타이밍 전략 백테스트에서 거래비용(1bp)을 공제한 후에도 Buy & Hold 대비 위험 조정 수익률이 개선되어 경제적 실용성 가능성을 시사하였다.

V. 결론 및 향후 과제

5.1 연구 요약

본 연구는 11개 ETF(주식·채권·원자재)를 대상으로, 거래일 기준 1~252일 지평에서 전방 실현분산을 예측하고, 이를 내재분산 proxy와 결합하여 분산 위험 프리미엄(VRP)을 산출·예측하는 통합 프레임워크

를 제시하였다. 실증에서는 피쳐-타겟 중첩을 방지하기 위해 전방 윈도우 기반 타겟을 구성하고, 정화 구간을 포함한 시계열 검증 절차를 적용하였다.

5.2 핵심 결과

실증 분석을 통해 (1) 다중 자산 통합 VRP 예측 구조의 실효성을 확인하였고, (2) 예측 지평에 따라 선형·신경망·트리 모델의 우위가 교차적으로 변동함을 발견하였다. 특히, (3) 복잡한 신경망보다 피쳐 선택과 정규화가 시계열 모델의 일반성 확보에 더 핵심적인 요인으로 작용하였으며, (4) 이러한 예측 우위는 거래비용 통제 하에서도 경제적 성과로 반영될 수 있음을 확인하였다.

5.3 경제적 함의

예측 결과가 실제 의사결정에 도움이 될 수 있는지 확인하기 위해, SPY를 대상으로 22거래일 WEns RV 예측값을 이용한 단순 변동성 타이밍 전략을 탐색적으로 실험하였다(예측 RV가 과거 중앙값보다 낮으면 레버리지 2x, 높으면 0.5x). 편도 1bp의 거래비용을 반영한 결과, Buy&Hold 대비 샵 비율이 0.705에서 0.804로, 연환산 수익률이 12.37%에서 19.44%로 개선되는 경향이 관측되었다.

다만 22거래일·블록·부트스트랩·검정에서 해당 개선이 5% 유의수준에 도달하지는 못했다($p=0.313$). 따라서 본 질의 결과는 성과를 입증하기보다, 예측 신호가 경제적 의사결정에 연결될 수 있는 가능성을 보여주는 탐색적 결과로 해석한다. 향후 다중 자산

메모 포함[55]: 구체적인 근거(수치적)가 부족한 것 같음

메모 포함[57]: RQ4의 실제 수치? 위의 4장에 언급 필요

메모 포함[56]: 결론 및 향후 과제 파트는 일반적으로 세부적인 소분류를 두지 않고 단락 중심으로 구성하는 경우가 많음. 연구 요약, 핵심 결과 등의 내용은 소단원 형태보다는 단락 구분을 통해 제시하는 방식으로 수정할 필요가 있음.

21 Weighted Ensemble을 활용한다. 다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측 포트폴리오 수준의 체계적 검증은 제안한다.

본 연구의 결과는 세 가지 학술적 함의를 가진다. 첫째, 자산군별 지평별로 예측 가능한 VRP 구조를 제시함으로써, 변동성 위험이 가격화되는 방식이 자산가격 이론에서 가정하는 위험회피-장기위험 채널과 정합적임을 실증적으로 뒷받침한다. 둘째, RV 예측이 이미 성숙한 분야인 상황에서, VRP를 예측 대상으로 삼아 선행트라딕터링을 공정 비교함으로써 금융 시계열 ML의 한계와 장점을 동시에 드러내는 새로운 벤치마크 문제를 제시한다. 셋째, 옵션 단면 없이도 공개 데이터로 다중 자산 VRP-proxy를 구축하고, 자산레짐-지평에 따른 구조적 차이를 체계적으로 문서화함으로써 향후 크로스애셋 변동성-프리미엄 연구의 기반 데이터를 제공한다.

5.4 한계와 향후 연구

본 연구는 공개 데이터 기반의 재현 가능한 다중 자산 통합 프레임워크를 목표로 하였기 때문에, 다음과 같은 한계가 존재한다.

고빈도 데이터(분 단위/틱)를 직접 사용하지 않고 OHLC 기반 proxy를 사용하였다.

내재분산은 자산별 옵션이 아닌 VIX 기반 공통 proxy로 구성하였으며, 이는 엄밀한 개별 자산별 물리적-위험중립 확률 측도 변환(Variance Swap) 과정과 궤적 차이가 있을 수 있다.

원자재 자산군에서는 주식 기반 VIX proxy가 완벽

하지 않을 수 있으며, 자산특화 변동성(GVZ, OVX) 통제로도 성과 개선에 한계가 존재함을 확인하였다.

본 연구는 이러한 데이터 상의 한계를 보완하기 위해 GARCH 시계열 벤치마크, ElasticNet 희소성(Sparsity) 기반 중요도 검증, 거래비용이 엄격히 통제된 전략 실효성 테스트를 보강 실험으로 포괄하였다. 이를 바탕으로 도출된 향후 연구 과제는 다음과 같다.

첫째, 단일 ETF(예: SPY) 타이밍 구성을 넘어 자산군 간 변동성 균형 가중치(Risk Parity) 최적화를 결합한 다중 자산 포트폴리오 차원의 강건성 고도화 검증이 요구된다.

둘째, 지수 옵션을 넘어 개별 자산 옵션의 가파른 스마일(Smile) 및 내재변동성 기간구조(Term Structure) 단면 데이터를 본 연구의 패널 구조에 결합하는 딥러닝 양상을 확장 연구를 제안한다.

References

References

- [1] S. Gu, B. Kelly, and D. Xiu, "Empirical asset pricing via machine learning", *The Review of Financial Studies*, Vol. 33, No. 5, pp. 2223-2273, May 2020.
- [2] F. Corsi, "A simple approximate long-memory model of realized volatility", *Journal of Financial Econometrics*, Vol. 7, No. 2, pp. 174-196, Mar. 2009.
- [3] F. Audrino and S. Knaus, "Lassoing the HAR model: A model selection perspective on realized volatility

메모 포함[58]: 4장에서 언급한 한계와 미해결 문제들이 여기서 자연스럽게 나오도록

- 22 Weighted Ensemble를 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측 dynamics", *Journal of Financial Econometrics*, Vol. 14, No. 2, pp. 392-427, 2016.
- [4] K. Christensen, M. Siggaard, and B. Veliev, "Volatility forecasting with machine learning and intraday commonality", *Journal of Financial Econometrics*, Vol. 22, No. 1, pp. 1-35, Jan. 2024.
- [5] P. Carr and L. Wu, "Variance risk premia", *The Review of Financial Studies*, Vol. 22, No. 3, pp. 1311-1341, Mar. 2009.
- [6] G. Bekaert and M. Hoerova, "The VIX, the variance premium and stock market volatility", *ECB Working Paper*, No. 1675, 2014.
- [7] T. Bollerslev, G. Tauchen, and H. Zhou, "Expected stock returns and variance risk premia", *The Review of Financial Studies*, Vol. 22, No. 11, pp. 4463-4492, Nov. 2009.
- [8] I. Drechsler and A. Yaron, "What's vol got to do with it", *The Review of Financial Studies*, Vol. 24, No. 1, pp. 1-45, Jan. 2011.
- [9] B. Zhang, Y. Chen, and Y. Lu, "Nonparametric estimation of variance risk premiums", *Journal of Financial Economics*, Vol. 142, No. 1, pp. 312-328, Oct. 2021.
- [10] M. Hattori, I. Shim, and Y. Sugihara, "The US variance risk premium and cross-market spillovers", *Bank for International Settlements Working Paper*, No. 713, Apr. 2018.
- [11] J. R. Ornelas et al., "Volatility risk premia and future commodity returns", *Bank for International Settlements Working Paper*, No. 619, 2018.
- [12] R. F. Engle, "Autoregressive conditional heteroskedasticity with estimates of the variance of United Kingdom inflation", *Econometrica*, Vol. 50, No. 4, pp. 987-1007, 1982.
- [13] T. Bollerslev, "Generalized autoregressive conditional heteroskedasticity", *Journal of Econometrics*, Vol. 31, No. 3, pp. 307-327, 1986.
- [14] P. Carr, L. Wu, and Z. Zhang, "Using machine learning to predict realized variance", *arXiv preprint*, 2019.
- [15] T. Dierckx, M. Davis, and W. Schoutens, "Machine learning for the FX variance risk premium", *Quantitative Finance*, Vol. 22, No. 1, pp. 129-143, Jan. 2022.
- [16] S. Heston and V. Todorov, "Exploring the variance risk premium across assets", *AEA Conference Paper*, 2024.
- [17] M. López de Prado, "Advances in financial machine learning", *Wiley*, 2018.

23 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

부록

37개 피쳐 상세 목록 (WEns Ridge 기준)

#	Group	Variable	Calculation & Description
1	HAR	LogRV_lag1	Prev-day Log-RV: $\log(RV_{t-1})$
2	HAR	LogRV_lag5	5d lag Log-RV: $\log(RV_{t-5})$
3	HAR	LogRV_lag10	10d lag Log-RV: $\log(RV_{t-10})$
4	HAR	LogRV_lag22	22d lag Log-RV: $\log(RV_{t-22})$
5	GARCH	Garch_Daily	Daily GARCH(1,1) vol (rolling fit)
6	GARCH	Garch_Weekly	Weekly GARCH vol (weekly returns)
7	HAR	LogRV_Std5	5d Vol-of-Vol: $\text{std}(\log RV, 5d)$
8	HAR	LogRV_Std22	22d Vol-of-Vol: $\text{std}(\log RV, 22d)$
9	HAR	RV_Mom5	5d vol momentum
10	HAR	RV_Mom22	22d vol momentum
11	Cross	SPY_LogRV	SPY Log-RV (market ref)
12	HAR	Ret_lag1	Prev-day log return
13	HAR	Ret_abs_lag1	Prev-day abs return
14	Cross	Corr_SPY	SPY corr (22d rolling)
15	HF	Parkinson_5	5d Parkinson vol
16	HF	Parkinson_22	22d Parkinson vol
17	HF	GarmanKlass_22	22d Garman-Klass vol
18	HF	RogersSatchell_22	22d Rogers-Satchell vol
19	HF	Range_Close_Ratio	Range-close ratio
20	HF	Overnight_Vol	Overnight vol
21	HF	Overnight_Ret	Overnight return

24 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

22	IV	IV_VIX	VIX level: log(VIX)
23	IV	IV_VIX_chg	VIX daily change
24	IV	IV_VIX_ma5	VIX 5d MA
25	IV	IV_VIX_std5	VIX 5d std (VVIX proxy)
26	IV	IV_VIX3M	VIX3M level: log(VIX3M)
27	IV	IV_VIX_TermSlope	VIX term slope
28	IV	IV_VIX9D	VIX9D level: log(VIX9D)
29	IV	IV_VIX_ShortSlope	VIX9D slope
30	IV	IV_VRP	VRP proxy: $VIX^2/100 - RV_SPY$
31	IV	IV_VRP_ma22	VRP 22d MA
32	Alt	AltVol_Amihud	Amihud illiquidity (22d)
33	Alt	AltVol_Vol_Ratio	Volume ratio (short/long)
34	Alt	AltVol_PV_Corr	Price-volume corr
35	Alt	AltVol_Vol_Surprise	Volume surprise (Z-score)
36	Alt	AltVol_Order_Imbalance	Signed volume imbalance
37	Alt	AltVol_Kyle_Lambda	Kyle Lambda (price impact)

표 하이퍼파라미터 최적 설정

Model	Hyperparameter	Value	Description
Ridge	alpha	10	L2 regularization strength
Lasso	alpha	0.01	L1 regularization strength
ElasticNet	alpha	0.01	Total regularization strength
	l1_ratio	0.5	Mix of L1 (0.5) and L2 (0.5)
SVR	kernel	rbf	Radial Basis Function kernel
	C	10	Regularization parameter
	epsilon	0.1	Epsilon-tube width
MLP	hidden_layer_sizes	64, 32	Two-layer architecture
	activation	relu	Rectified Linear Unit


25 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

	early_stopping	TRUE	Terminate if val-loss plateaus
	random_state	42	Deterministic initialization
Random Forest	n_estimators	200	Number of trees
	min_samples_leaf	20	Minimum samples in leaf node
XGBoost	n_estimators	300	Boosting rounds
	learning_rate	0.05	Learning rate
	reg_lambda	1	L2 regularization
LightGBM	n_estimators	300	Boosting rounds
	num_leaves	31	Max leaves in one tree

본 연구의 모든 비교 모델들의 최종 하이퍼파라미터는 학습 구간 내 5-fold TimeSeriesSplit(시계열 교차검증)을 통해 탐색 및 선택되었으며, 표 A-5는 그 최종 결과치를 요약한 것이다.

그림 WEns 모델의 전체 흐름

26 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측



27 Weighted Ensemble을 활용한다중 예측 기간 Cross-Asset 분산 리스크 프리미엄 예측

저자소개

