

Abstract

본 연구는 주식(5), 채권(3), 원자재(3)로 구성된 11 개 ETF 를 대상으로, 공개 OHLCV 데이터와 VIX 기간구조 지표만을 이용해 분산 위험 프리미엄(VRP)을 예측하는 프레임워크를 제시한다. 예측 지평은 거래일 기준 1, 5, 22, 60, 90, 120, 180, 252 의 8 개 구간이며, (1) 전방 실현분산을 먼저 예측하고 (2) 내재분산 프록시와 결합해 VRP 를 산출하는 2 단계 구조를 사용한다. 동일한 피처와 동일한 검증 절차 하에서 선형(정규화 회귀), 트리, 딥러닝(시계열) 모델을 비교한 결과, 예측 지평에 따라 유리한 모델 구조가 달라지는 경향이 확인되었다. 단기(1~22 거래일)에서는 정규화 선형 모델이, 중기(60~90 거래일)에서는 시계열 신경망이, 장기(180~252 거래일)에서는 트리 기반 모델이 상대적으로 안정적인 성능을 보였다. 추가로 통계적 유의성 검정과 만기 불일치·결측 처리·자산특화 지표 대체 등 강건성 검증을 통해 제안 방법의 신뢰도를 점검하였다.

1. 서론

최근 금융시장은 팬데믹, 지정학적 충격, 통화정책 전환과 같은 사건을 거치며 높은 변동성 국면을 반복적으로 경험해 왔다. 예를 들어 코로나 19 팬데믹이 본격화된 2020 년 3 월 16 일 CBOE VIX 지수는 82.7 수준까지 상승하였고, 러시아-우크라이나 전쟁 발발 후인 2022 년 3 월 초에도 36.5 수준까지 상승하였다. 본 연구에서 사용한 VIX 수치는 CBOE 원지표를 Yahoo Finance 를 통해 수집한 값이다. 이러한 사례는 변동성이 단순한 가격 변동 폭을 넘어, 시장의 불확실성 평가와 위험회피 수요를 집약적으로 반영하는 변수임을 보여준다.

금융시장에서 변동성 연구는 크게 두 가지 질문으로 구분될 수 있다. 첫째는 미래 변동성의 수준이 어느 정도가 될 것인가의 문제이며, 둘째는 그러한 위험이 시장에서 얼마나 비싸게 가격화되는가의 문제이다. 실현분산(realized variance, RV)은 전자와 직접적으로 연결되고, **분산 위험 프리미엄(variance risk premium, VRP)**은 후자와 더 밀접하게 연결된다. VRP 는

일반적으로 위험중립 기대분산과 물리적 기대분산의 차이로 해석되며, **변동성 위험의 가격화(price of volatility risk)**를 나타내는 지표로 이해된다 [5]-[8].

금융 예측에서 가장 직관적인 목표는 수익률 또는 초과수익률이지만, 수익률은 신호 대 잡음 비율이 낮고 구조 변화의 영향을 크게 받기 때문에 안정적인 예측이 어렵다. Gu, Kelly, and Xiu[1]는 다양한 기계학습 방법을 비교하며 자산가격 예측에서 기계학습의 가능성을 제시하였지만, 동시에 금융 예측이 본질적으로 어려운 문제라는 점도 보여주었다. 반면 변동성은 군집성과 지속성이 강하므로 수익률보다 예측 가능성이 상대적으로 높다. Corsi[2]의 HAR-RV 모형은 일·주·월 수준의 변동성 정보를 결합하여 이러한 특성을 간명하게 반영한 대표적 접근이며, 이후 Audrino and Knaus[3], Christensen, Siggaard, and Veliyev[4] 등은 정규화 회귀와 기계학습을 활용한 변동성 예측의 확장 가능성을 보였다.

본 연구는 분산(variance) 단위로 용어를 통일하며, 내재분산(IV), 실현분산(RV), 분산 위험 프리미엄($VRP = IV - RV$)을 핵심 변수로 사용한다. 본 논문에서 사용하는 주요 기호는 다음과 같다.

표 1. 주요 기호 및 정의

Symbol	Definition
$RV_{i,t}(h)$	Forward RV of asset i , h trading days ahead (annualized)
IV_t^2	Implied variance proxy, $(VIX_t / 100)^2$
$VRP_{i,t}(h)$	Variance risk premium, $IV_t^2 - RV_{i,t}(h)$
h	Forecast horizon (trading days), $h \in \{1, 5, 22, 60, 90, 120, 180, 252\}$
i	Asset index ($i=1, \dots, 11$; 11 ETFs)
t	Time index (trading day)
r_t	Daily log return, $\ln(P_t/P_{t-1})$
R^2	Coefficient of determination; pooled and median R^2

예를 들어 VIX 수준과 RV 의 조합에 따라 VRP 가 양·음수로 크게 달라질 수 있으며, 이는 시장이 변동성 위험을 얼마나 비싸게 평가하는지를 보여준다.

모델은 전방 윈도우(forward window) 방식으로 $\log(RV)$ 를 직접 예측한 뒤, 관측 가능한 IV 와 결합해 VRP 를 산출하는 2 단계 구조를 따른다. 예측 시점에서 미래 정보가 섞이는 데이터 누출을 방지하기 위해 피처와 타겟 구간은 엄격하게 분리되는데, 피처는 $[t-W, t]$ 구간의 과거 OHLCV·변동성·보조 데이터, 타겟은 $[t+1, t+h]$ 구간의 전방 h 일 실현분산이다.

용어와 산출 절차의 상세 정의는 3 장에서 기술한다.

본 연구의 예측 지평은 모두 거래일 기준이며, $h \in \{1, 5, 22, 60, 90, 120, 180, 252\}$ 로 설정한다. 상세 설정과 정화 구간(purge gap) 처리는 3 장에서 기술한다.

VRP 관련 연구는 (i) VRP 의 측정과 추정, (ii) VRP 의 경제적 의미와 자산가격 함의, (iii) 특정 시장(주로 주식지수) 중심의 실증 분석으로 축적되어 왔다. 그러나 “VRP 예측” 관점에서는 다음의 공백이 남아 있다.

첫째, 다중 자산 VRP 연구는 대체로 자산별 옵션 자료에 의존한다. 반면 실제 분석 환경에서는 주식·채권·원자재 전체에 대해 장기간 옵션 데이터를 확보하기 어렵다. 본 연구는 11 개 ETF 의 일별 OHLCV 와 공개 변동성 지표를 결합하여, 다중 자산 VRP 예측을 재현 가능한 형태로 구성한다.

둘째, VRP 연구는 월간(대략 30 일) 지표(VIX)에 정렬된 분석이 많아, 1~5 거래일부터 연간(252 거래일)까지 지평을 확장했을 때 예측 구조가 어떻게 달라지는지에 대한 체계적 비교가 충분하지 않다.

셋째, 금융 데이터는 구조 변화가 잦고 노이즈가 큰 편이어서 “복잡한 모델이 항상 더 낫다”고 말하기 어렵다. 그럼에도 동일한 피처·동일한 검증 절차 아래에서 선형 모델, 트리 기반 모델, 시계열 신경망 모델을 지평별로 공정 비교한 결과는 제한적이다.

이 공백을 바탕으로 본 연구는 다음 연구 질문에 답한다.

RQ1. 공개 데이터(가격 기반 피처와 변동성 지표)를 이용해 구성한 예측 VRP(이하 $VRP_{\hat{}}$)는 주식·채권·원자재 자산군에서 예측 가능한가?

RQ2. 예측 지평이 1 거래일에서 252 거래일까지 길어질 때, 예측 성능(R^2 , RMSE)과 유효 피처는 어떻게 달라지는가?

RQ3. 동일한 피처와 동일한 시계열 검증 절차에서, 선형·트리 기반·시계열 신경망 모델의 상대적 성능은 지평에 따라 어떻게 달라지는가?

RQ4. $VRP_{\hat{}}$ 예측의 통계적 우위가 실제 거래비용을 반영한 경제적 의사결정(예: 변동성 타이밍 전략)에서도 실효성을 가지는가?

본 연구는 주식(5), 채권(3), 원자재(3)로 구성된 총 11 개 ETF(SPY, QQQ, IWM, EFA, EEM, TLT, IEF, AGG, GLD, SLV, USO)를 대상으로 2010 년 1 월부터 2025 년 1 월까지 일별 OHLCV 데이터를 사용한다.

피처는 (i) HAR 구조 기반의 기본 피처, (ii) OHLC 로부터 계산한 range 기반 변동성 피처, (iii) VIX 기간구조(예: VIX3M, VIX9D 등)와 같은 변동성 지표 피처, (iv) 거래량 기반 피처로 구성한다. 또한 단일 VIX 를 모든 지평의 타겟 IV 로 대체할 때 발생하는 만기 불일치(maturity mismatch) 문제를 점검하고, VIX 기간구조 지표(VIX9D, VIX3M)로 이를 부분적으로 보완한다. 1~5d 지평에서는 VIX9D 대체가 소폭 유리하나, 월간 이상에서는 VIX 단독이 크게 열등하지 않다는 사전 검증 결과를 포함한다.

원자재의 경우 주식 기반 VIX 가 충분하지 않을 수 있으므로, 금(GVZ), 원유(OVX) 등 자산특화 변동성 지표를 대체 적용하는 강건성 검증을 수행한다(소폭 개선이 있으나 전체 성능 변화는 제한적).

성능 평가는 R^2 (설명력)과 RMSE(예측오차)를 기반으로, 시간순 학습/테스트 분할과 확장 윈도우 교차검증을 적용한다.

본 논문의 구성은 다음과 같다. 2 장에서는 VRP 측정·예측 관련 선행연구를 정리한다. 3 장에서는 데이터·변수 구성 및 방법론을 제시한다. 4 장에서는 실험 결과와 논의를 보고하고, 5 장에서 결론 및 향후 과제를 정리한다.

2. 관련 연구

VRP 관련 문헌은 크게 세 흐름으로 정리할 수 있다. 첫째는 VRP 의 정의와 측정에 관한 연구이다. Carr and Wu[5]는 옵션 포트폴리오를 활용해 위험중립 기대분산을 근사할 수 있음을 보였고, 이를 바탕으로 실현분산과의 차이를 VRP 로 정의하는 방법을 제시하였다. 둘째는 VRP 의 경제적 의미와 자산가격 함의에 관한 연구이다. Bekaert and Hoerova[6], Bollerslev, Tauchen, and Zhou[7], Drechsler and Yaron[8]은 VRP 가 단순한 변동성 수준이 아니라 위험이 시장에서 얼마나 비싸게 거래되는지를 보여주는 지표임을 제시하였다. 셋째는 VRP 의 예측력과 시장 간 전이, 그리고 자산군별 이질성을 다루는 연구이다 [9]-[16].

한편 VRP 는 IV 와 RV 의 차이로 정의되므로, RV 예측 문헌과도 밀접하게 연결된다. 전통적 변동성 예측은 GARCH 계열 모형[12][13]에서 출발하여, 다중 스케일 구조를 반영하는 HAR-RV 모형[2]으로 확장되었다. 이후 Audrino and Knaus[3]는 HAR 구조와 변수 선택을 결합한 LASSO-HAR 를 제시하였고, Christensen, Siggaard, and Veliyev[4]는 다양한 기계학습 모형이 변동성 예측에서 경쟁력 있는 성능을 보일 수 있음을 보고하였다. 이와 같은 연구 흐름은 고차원 피처와 비선형 모형의 활용 가능성을 보여주지만, 동일 피처와 동일 검증 절차 아래에서 예측 지평별 모형 차이를 비교한 연구는 상대적으로 제한적이다.

다중 자산 VRP 연구도 존재하지만, 대부분 각 자산별 옵션 데이터를 전제로 한다 [10][11][16]. 이러한 접근은 측정의 정밀성은 높을 수 있으나, 장기간 데이터 확보와 자산군 간 비교의 실용성 측면에서는 제약이 따른다. 본 연구는 공개 OHLCV 데이터와 공개 변동성 지표만을 사용하여 재현 가능한 VRP proxy 를 구축하고, 만기 불일치와 자산특화 변동성 지표의 필요성은 별도의 강건성 검증으로 점검한다. 따라서 본 연구는 VRP 측정 문헌, RV 예측 문헌, 그리고 기계학습 기반 금융예측 문헌을 연결하면서, 재현성과 확장성을 강조한 다중 자산·다중 지평 연구로 위치 지을 수 있다.

3. 데이터 및 변수 구성

3.1 데이터

본 연구는 SPY, QQQ, IWM, EFA, EEM, TLT, IEF, AGG, GLD, SLV, USO 의 총 11 개 ETF 를 분석 대상으로 사용한다. 데이터는 Yahoo Finance API 를 통해 수집하였으며, 수집 파라미터는 `start='2010-01-01'`, `end='2025-01-01'` 이다. `yfinance` 의 `end` 파라미터가 배타적이라는 점을 고려하면 실제 표본 구간은 2010 년 1 월 4 일부터 2024 년 12 월 31 일까지이다. 총 거래일 수는 약 3,780 일이다.

표본 시작 시점을 2010 년으로 설정한 이유는 다음과 같다. 첫째, 11 개 ETF 와 VIX/VIX3M 등 변동성 지표의 공통 가용 구간을 안정적으로 확보하기 위해서다. 둘째, 2008~2009 년 금융위기 직후 구간은 VIX 급등과 유동성 위축이 동시에 나타난 극단적 비정상 구간이므로, 이를 학습 표본에 포함하면 특정 위기 레짐에 과적합될 가능성이 있다. 셋째, VIX9D 결측이 표본 초기에 제한적으로 나타나도록 하여 전체 표본의 일관성을 높이고자 하였다. 따라서

2010 년 시작은 단순한 데이터 편의가 아니라 자산 공통성, 지표 가용성, 레짐 안정성을 함께 고려한 선택이다.

본 연구에서 “안정적으로 존재하는 자산”이란 2010 년 1 월 4 일 이후 Yahoo Finance 에서 일별 OHLCV 5 개 항목이 연속 거래일 기준으로 대부분 결측 없이 제공되며, 단기 결측이 존재하더라도 1~2 거래일 수준에 그치는 자산을 의미한다. 별도의 거래량 하한이나 유동성 컷오프를 적용하지는 않았으나, 선택된 11 개 ETF 는 각 자산군에서 대표성을 가진 대형 ETF 이므로 유동성 문제는 실질적으로 크지 않다.

3.1.1 수익률 및 가격 조정(배당/분할) 처리

일별 수익률은 로그수익률로 정의한다.

$$r_t = \ln(P_t / P_{t-1})$$

여기서 P_t 는 yfinance 에서 제공하는 **수정 종가(배당/분할 반영 Close)**를 사용한다.

OHLC 는 수정되지 않은 원시 데이터를 사용하며, 배당락으로 인한 가격 점프가 range 추정량에 미치는 영향은 22 거래일 롤링 윈도우 기준으로 제한적임을 확인하였다.

3.2 결측치 처리

결측치는 전방 채움(forward fill)으로 처리하였다. 이는 미래 정보 누출을 방지하면서 시계열 연속성을 유지하고 표본 손실을 최소화하기 위한 선택이다. 선형 보간은 미래 시점의 정보를 사용할 수 있으므로 시계열 예측에서 적절하지 않을 수 있으나, 전방 채움은 과거 관측치만을 이용한다. 또한 결측 행을 그대로 삭제할 경우 5 일, 22 일 등 다중 윈도우 기반 피쳐 계산과 GARCH 추정의 안정성이 저하될 수 있다. 전방 채움 적용 시 표본 수는 41,261 개였고, 이를 제거하면 38,489 개로 감소하였다.

추가 강건성 검증 결과, 전방 채움을 제거한 경우 풀링 R^2 는 0.782 에서 0.795 로, 중위 R^2 는 0.123 에서 0.182 로 소폭 상승하였다. 이는 전방 채움이 성능을 인위적으로 부풀리지 않았음을 의미하며, 오히려 보수적인 방향으로 작용했음을 시사한다. 따라서 본 연구의 핵심 결과는 결측 처리 방식에 과도하게 의존하지 않는다.

3.3 변수 정의와 2 단계 예측 구조

본 연구는 분산 단위로 용어를 통일한다. 내재분산은 변동성 지수를 제공하여 근사한 값으로 두고, 실현분산은 미래 h 거래일 동안의 수익률 제곱합을 연율화한 값으로 정의한다. 이에 따라 분산 위험 프리미엄은 $VRP_{i,t}(h) = IV_t^2 - RV_{i,t}(h)$ 로 정의한다.

본 연구의 핵심 설계는 VRP 를 직접 예측하지 않고, 먼저 미래 실현분산 RV 를 예측한 뒤 사후적으로 내재분산과 결합하여 VRP 를 계산하는 2 단계 구조이다. 이 구조를 채택한 이유는 피처와 타겟 간 정보 중첩을 줄이기 위해서다. 만약 VRP 자체를 직접 타겟으로 두면, 타겟 정의식 ($IV - RV$) 안에 포함된 IV 정보가 피처로 사용되는 VIX 계열 지표와 중복될 수 있다. 반면 RV 만을 예측 대상으로 두면, 모형은 미래 변동성 자체를 학습하고, 관측 가능한 IV 는 사후 결합에 활용되므로 역할이 명확히 분리된다. 이런 점에서 2 단계 구조는 예측의 해석 가능성과 설계의 타당성을 높인다.

본 연구의 예측 지평 h 는 모두 거래일(trading days) 기준으로 정의하며, $h \in \{1, 5, 22, 60, 90, 120, 180, 252\}$ 로 설정한다.

실현분산 $RV_{i,t}(h)$ 는 자산 i 의 시점 t 이후 향후 h 거래일 구간 $[t+1, t+h]$ 에서 실현된 수익률 제곱의 평균을 연율화하여 구성한다.

$$RV_{i,t}(h) = \text{mean}(r_{[t+1:t+h]}^2) \times 252$$

실현분산은 일반적으로 강한 우편향을 띠므로, 통계적 모델링의 안정성을 확보하기 위해 타겟(target)에 로그 변환을 적용한다.

$$\text{target}(t, h) = \log(RV_{i,t}(h)) = \log(\text{mean}(r_{[t+1:t+h]}^2) \times 252)$$

내재분산 $IV_t(h)$ 는 시장의 공통 불확실성을 대변하는 CBOE VIX 등락을 기준으로 산출한다.

$$IV_t^2 = (VIX_t / 100)^2$$

만기 불일치의 실질적 영향을 확인하기 위해 VIX 단독, VIX9D 대체, VIX3M 대체, 전체 IV 동시 투입의 네 설정을 비교하였다. 그 결과 22d 이상에서는 VIX 단독이 일관적으로 최적(R^2 0.769~0.675)이며, 1~5d 에서만 VIX9D 대체가 소폭 유리(+0.01 수준)하였다. 지평별 상세 수치는 부록을 참조한다.

원자재는 주식 기반 VIX 와 다른 구조를 가질 수 있으므로, 금과 원유에 대해 CBOE 의 자산특화 변동성 지표(GVZ, OVX)를 대체 적용하는 강건성 검증을 수행하였다. 일부 개선이 있으나 전체 성능 변화는 제한적이어서 단일 VIX 기반 proxy 사용의 타당성이 유지된다.

3.4 22 거래일 지평의 Weighted Ensemble

22 거래일 지평에서는 Ridge 와 XGBoost 를 결합한 weighted ensemble 을 사용하였다. 구체적으로 자산군별 Ridge 예측값에 70%, 전체 자산 통합 XGBoost 예측값에 30%의 가중치를 부여하였다. Ridge 는 다중공선성에 상대적으로 강하고 선형적 구조를 안정적으로 포착하는 장점이 있으며, XGBoost 는 비선형 상호작용을 보정하는 역할을 수행한다. 따라서 두 모형의 결합은 안정성과 유연성의 절충으로 이해할 수 있다.

가중치 선택의 타당성을 점검하기 위해 Ridge:XGBoost 비율을 0:100 부터 100:0 까지 10% 단위로 비교하였다. 그 결과 폴링 R^2 는 80:20 에서 최대 0.7969, 중위 R^2 는 50:50 에서 최대 0.2103 을 기록하였다. 본 연구가 채택한 70:30 조합은 폴링 $R^2=0.7965$, 중위 $R^2=0.1985$ 로 두 지표 모두 상위 안정 구간에 위치하였다. 특히 60:40~80:20 범위가 전반적으로 우수한 구간으로 확인되었으며, 전체 가중치 범위에서 폴링 R^2 변동 폭도 3.5%p 이내에 머물렀다. 따라서 70:30 은 특정 지표 하나에만 최적화된 값이라기보다, 선형 안정성과 비선형 보정의 균형을 고려한 보수적 선택으로 해석할 수 있다.

3.5 최종 패널 데이터 구성(정렬 및 사용 가능 표본)

본 연구의 데이터는 “날짜 × 자산” 패널 형태로 구성된다. 각 날짜 t 에서 피처(feature, 설명변수)는 $t - 1$ 까지의 정보로 계산하고, 타겟은 $[t+1, t+h]$ 구간에서 계산된 전방 실현분산(로그)이다. 따라서 각 지평 h 에 대해 표본의 끝부분 h 일은 타겟을 계산할 수 없으므로 학습/평가에서 제외된다.

또한 예측 지평이 긴 경우 타겟 윈도우가 겹치면서 검증 누출 가능성이 커질 수 있으므로, 학습/테스트 분할 경계와 교차검증 폴드 경계에 예측 지평 h 만큼의 정화 구간을 두어 타겟 윈도우 중첩을 완화한다.

3.6 피처(Features) 구성 및 전처리

피처는 (i) HAR 기반 래그, (ii) OHLC range 기반 변동성 추정량(HF proxy), (iii) IV 기간구조/VRP 통계(IV surface), (iv) 대안 데이터(alternative data; 거래량 기반 피처)로 구성된 다중 그룹을 사용한다(총 37 개 피처). 모델 간 비교에서는 동일 피처 세트 조건을 유지하여 공정성을 확보한다.

또한 피처 스케일 차이를 줄이기 위해 표준화(예: StandardScaler)를 적용하며, 스케일링 파라미터는 학습 구간에서만 추정하여 테스트 구간으로 정보가 누출되지 않도록 한다. (해당 구현 원칙은 학습/검증 절차에서 일관되게 적용된다.)

3.7 평가 지표 및 통계적 검정

평가지표는 중위 R^2 를 1 순위, 폴링 R^2 를 보조 지표로 보고한다(폴링 R^2 는 자산 간 스케일 차이의 영향을 받을 수 있음).

모델 간 차이의 통계적 유의성은 Diebold–Mariano(DM) 검정으로 평가한다. 예측 타겟이 일정 기간 $[t+1, t+h]$ 의 평균으로 구성되어 인접한 날짜 간에 타겟 윈도우가 필연적으로 겹치므로, 예측오차 간에 최대 $h-1$ 차 자기상관이 존재한다. 이에 따라 DM 검정에서는 지평 h 를 Newey–West HAC 대역폭(bandwidth)으로 사용하여 중첩 구조에 의한 분산 과소추정을 보정한다. 장기 지평($h \geq 120$)에서는 점근 근사의 한계를 보완하기 위해 블록 부트스트랩(block size= h , $B=5,000$)을 보조 검정으로 사용하여 유의성을 재확인한다.

4. 실험 결과 및 논의

4.1 실험 개요와 보고 원칙

본 연구는 11 개 ETF 패널 자료를 대상으로, 8 개 예측 지평(표 1 참조)에서 3.3 절의 2 단계 구조에 따라 전방 실현분산을 예측하고, 내재분산 대용치와 결합해

$$VRP_hat_{i,t}(h) = IV_t^2 - RV_hat_{i,t}(h)$$

를 산출한다.

4.1.1 VRP 예측 성능의 보고 방식

본 연구에서 예측 시점의 내재분산 대용치(IV_t^2)는 이미 관측된 값이므로, VRP 예측 오차는 RV 예측 오차와 부호만 반대이고 기계적으로 절대적 크기가 동일하다. 따라서 모델 간 우열 비교와 선택은 1 단계 RV 예측 성능 비교로 일관되게 수행할 수 있다.

성능 지표는 횡단면 변동의 영향을 배제한 순수 시계열 예측력을 보기 위해 중위 R^2 (자산별 R^2 중위값)를 1 순위로, 풀링 R^2 를 보조 지표로 보고한다.

4.2 지평별 대표(챔피언) 모델 요약

지평별로 가장 높은 성능을 보인 모델은 다음과 같이 요약된다. 1~22d 구간에서는 ElasticNet-59(풀링 R^2 0.807), 60~90d 에서는 BiLSTM-A(3 range 피쳐, 풀링 R^2 0.796), 120d 에서는 HAR-3(0.758), 180~252d 에서는 Random Forest(각각 0.719, 0.705)가 가장 높은 풀링 R^2 를 기록하였다. 이처럼 예측 지평이 바뀌면 유리한 모델 구조가 달라지는 패턴이 관측된다.

1~22d 구간에서는 피쳐가 많을수록(특히 range/기간구조/거래량 포함) 선형 결합과 앙상블 모델이 가장 우수하였다. 반면 60~90d 지평에서는 37 개 전체 피쳐 대신 3 개의 핵심 range 피쳐만 압축적으로 채택한 LSTM 모델이 오히려 가장 우수한 예측력을 보였다(60d 풀링 R^2 0.796). 더 길어진 180~252d 지평에서는 트리 구조 알고리즘인 Random Forest 가 가장 높은 풀링 R^2 를 기록하는 이질적인 결과를 확인하였다.

표 4 는 주요 모델의 지평별 풀링 R^2 를 종합적으로 비교한 것이다. 1~22d 에서 WEns Ridge 가 우위, 60~90d 에서 BiLSTM-A 이 우위, 180~252d 에서 RF/HAR-3 가 우위를 보이는 교차 패턴이 뚜렷이 관측된다.

표 4. Multi-Horizon 풀링 R^2 비교 (주요 모델)

h	Ridge(37)	BiLSTM-A(3)	HAR-3(3)	LASSO(37)	RF(37)	Champion
1d	0.114	0.092	0.109	0.116	0.113	LASSO
5d	0.625	0.577	0.581	0.625	0.611	Ridge
22d	0.798	0.780	0.761	0.790	0.770	Ridge
60d	0.774	0.796	0.784	0.782	0.752	BiLSTM-

h	Ridge(37)	BiLSTM-A(3)	HAR-3(3)	LASSO(37)	RF(37)	Champion
						A
90d	0.752	0.788	0.781	0.763	0.737	BiLSTM-A
120d	0.737	0.751	0.758	0.748	0.730	HAR-3
180d	0.691	0.708	0.705	0.707	0.719	RF
252d	0.516	0.589	0.611	0.555	0.705	RF

표 5. 지평별 챔피언 모델의 전반적 설명력(중위 R^2) 요약

h	Best Model (Type)	Pooled R^2	Median R^2
1d	LASSO (Linear)	0.116	0.019 (WEns)
5d	Ridge (Linear)	0.621	0.203 (WEns)
22d	ElasticNet-59 / WEns (Linear/Ensemble)	0.807 / 0.803	0.097 / 0.215
60d	BiLSTM-A (DL)	0.796	0.150
180d	RF (Tree)	0.719	-0.456
252d	RF (Tree)	0.705	-0.482

주: 풀링 R^2 는 기저 변동성이 큰 자산에 의해 과대평가될 수 있으므로, 모델의 전반적 설명력을 가늠하는 보수적 수단으로 챔피언 모델 계열의 자산별 중위 R^2 를 함께 보조 지표로 참조하였다. 장기 지평(180d 이상)으로 갈수록 중위 R^2 가 음수로 돌아서며 예측이 급격히 어려워짐을 알 수 있다.

4.3 22 거래일 지평에서의 주요 결과: WEns 앙상블

22 거래일 예측에서 대표적인 최고 성능 모델은 **WEns(Ridge 70% + XGBoost 30% 가중 앙상블, 37 피쳐)**이며, 풀링 R^2 0.803, 중위 R^2 0.215 를 기록하였다.

표 6. WEns 앙상블의 지평별 성능(발체)

h	Pooled R^2	RMSE	MAE	QLIKE	Median R^2
1d	0.1170	2.4922	1.7467	3.4431	0.0291
5d	0.6238	0.7490	0.5908	0.3229	0.1801
22d	0.7965	0.4683	0.3769	0.1271	0.1985

h	Pooled R ²	RMSE	MAE	QLIKE	Median R ²
60d	0.7892	0.4557	0.3602	0.1267	0.0092
90d	0.7673	0.4711	0.3759	0.1367	-0.3465
120d	0.7496	0.4832	0.3863	0.1454	-0.5156
180d	0.7434	0.4817	0.3860	0.1451	-0.7267
252d	0.7034	0.5102	0.4117	0.1662	-1.8437

표 6 에 나타나듯, WEns 앙상블은 22 거래일(월간) 지평에서 최적의 예측력을 보이지만, 60 거래일(분기) 이상으로 지평이 확장될 경우 시계열 설명력을 엄밀히 대변하는 중위 R² 가 음수(-) 영역으로 진입한다. 이는 단일 풀링(pooling) 모델이 180~252d 지평에서 각 자산군이 갖는 독자적인 변동성 구조를 동시에 모두 적합(fit)시키는 데 한계가 있음을 시사한다.

4.3.1 180~252d 중위 R² 음수의 해석

장기 지평에서 중위 R² 가 음수로 전환되는 현상은 (1) Equity/Bond/Commodity 간 변동성 동학 이질성으로 인해 단일 풀링 모델이 모든 자산 패턴을 동시에 포착하기 어렵고, (2) 지평이 길어질수록 조건부 모델의 상대적 우위가 감소하여 비조건부 평균이 더 강한 예측기가 되는 SNR 감소를 반영한다. 180~252d 예측에서는 자산군별 적응 전략이 필요함을 시사한다.

자산군별 252d 중위 R² 를 분해하면, Equity(5 종) -1.82, Bond(3 종) -4.31, Commodity(3 종) -5.64 로 채권과 원자재가 주식 대비 훨씬 낮다. 이 중 Equity 내에서도 SPY·QQQ 는 양수를 유지하나 EEM·EFA 는 큰 음수를 기록한다.

채권과 원자재 자산군은 180~252d 이상 지평에서 눈에 띄게 더 낮은 R² 성과를 보인다. 주식과 뚜렷이 구별되는 채권의 듀레이션 리스크 분포, 그리고 원자재의 콘탱고/백워데이션 구조 차이 등이 단일 풀링 모델 구축 시 교란 요인으로 작용했음을 시사한다.

4.3.2 자산별 개별 예측 성능

표 7 는 WEns 앙상블의 22 거래일 지평에서 11 개 ETF 각각의 개별 R² 를 보고한다. 풀링 R²(0.803)는 자산 간 수준 차이(횡단면 변동)를 포함하므로 높은 값을 보이지만, 개별 자산

R^2 는 순수 시계열 예측 정확도를 반영하여 상대적으로 낮다. 주식(Equity) 자산군, 특히 SPY 와 QQQ 가 가장 높은 개별 R^2 를 기록하였으며, 채권(Bond)은 예측 난이도가 높은 것으로 나타났다.

표 7. WEns 앙상블의 자산별 예측 성능 (22d 전방 RV)

Asset	Class	R^2	RMSE	Rating
SPY	Equity	0.299	0.379	Good
QQQ	Equity	0.262	0.437	Good
IWM	Equity	0.215	0.409	Fair
EFA	Equity	0.139	0.405	Fair
EEM	Equity	0.059	0.441	Fair
TLT	Bond	-0.003	0.568	Poor
IEF	Bond	0.030	0.523	Fair
AGG	Bond	0.019	0.481	Fair
GLD	Commodity	0.105	0.413	Fair
SLV	Commodity	0.119	0.475	Fair
USO	Commodity	-0.081	0.592	Poor
Pooled	All	0.803	0.468	Overall

개별 자산 R^2 와 풀링 R^2 의 큰 괴리는 모델의 예측력이 상당 부분 자산 간 횡단면 변동에 의존하고 있음을 시사하며, 이는 중위 R^2 를 1 순위 지표로 사용하는 본 연구의 보고 방식의 타당성을 뒷받침한다.

4.4 모델 비교(9 개 모델)와 핵심 관찰

다음 표는 대표 8 개 모델의 성능을 비교한 결과이다. 풀링 R^2 기준으로는 선형 모델(Lasso/ElasticNet)이 상위권을 차지하며, 중위 R^2 기준으로는 Random Forest 가 상대적으로 높게 나타난다. SVR, MLP 는 중위 R^2 가 크게 음수로 나타나 안정적 일반화가 어려웠다.

표 8. 다중 모델 비교(요약, 22d)

Model	Type	Pooled R^2	Median R^2
Lasso	Linear	0.7712	0.0998
ElasticNet	Linear	0.7696	0.0742

Model	Type	Pooled R^2	Median R^2
Ridge(pooled)	Linear	0.7625	-0.0030
Ridge(per-class)	Linear	0.7618	0.0949
RF	Tree	0.7590	0.1424
LightGBM	Tree	0.7387	0.0589
XGBoost	Tree	0.7330	0.0353
SVR	Kernel	0.6901	-0.0939
MLP	NN	0.61	-0.3266

이는 '기계학습 모델의 구조가 복잡할수록 시계열 예측 성능도 우상향할 것'이라는 통념과 배치된다. 변동성 예측 환경 특유의 (i) 강한 자기상관 구조, (ii) 높은 잡음, (iii) 국면(레짐) 변화가 공존하기 때문에, 적절한 규제를 부여한 선형 모델이 테스트 구간에서 예측의 분산을 제어하며 더 안정적인 성능을 보일 수 있다.

4.4.1 다중 모델 공정 비교 (Fair Comparison)

표 9 은 본 연구에서 **동일 데이터(11 개 ETF, 2010~2025)·동일 37 개 피처·동일 검증 절차(80:20 temporal split, purge=h)**를 적용하여 수행한 공정 비교 결과이다. 이 표의 모든 수치는 동일 조건에서 산출되었으므로 직접적인 모델 간 우열 비교가 가능하다.

표 9. 본 연구 내 공정 비교표 (Fair Comparison, 22d)

Model	Type	#Feat	Features	Pooled R^2	Median R^2	RMSE	Note
GARCH (1,1)	TS	–	Daily log returns	0.6939	0.0273	0.5782	Traditional benchmark
GJR-GARCH	TS	–	Asymmetric returns	0.6989	-0.0066	0.5735	Asymmetry effect
HAR-3	Linear	3	RV lags	0.7610	0.1709	0.5415	Base benchmark
Ridge (pooled)	Linear	37	Full	0.7625	-0.0030	0.5093	Single pooling

Model	Type	#Feat	Features	Pooled R ²	Median R ²	RMSE	Note
Ridge (per-class)	Linear	37	Full	0.7618	0.0949	0.5101	Per-class
Lasso	Linear	37	Full	0.7712	0.0998	0.4999	L1 reg.
Elastic Net	Linear	37	Full	0.7696	0.0742	0.5017	L1+L2
RF	Tree	37	Full	0.7590	0.1424	0.5130	–
XGBoost	Tree	37	Full	0.7330	0.0353	0.5400	–
LightGBM	Tree	37	Full	0.7387	0.0589	0.5342	–
SVR	Kernel	37	Full	0.6901	-0.0939	0.5818	–
MLP	NN	37	Full	0.6183	-0.3266	0.6457	Overfitting
BiLSTM-A	DL	3	Range (RS,GK, RC)	0.7800	0.2353	0.4767	3-feat design
WEEns	Ensemble	37	Full	0.8030	0.2150	0.4680	Ridge 70%+XGB 30%
Elastic Net-59	Linear	59	Extended feat.	0.8070	–	0.4591	Best pooled

주: BiLSTM-A 는 과적합 방지를 위해 의도적으로 3 개 range 피처만 사용하며(4.4.2 절 참조), ElasticNet-59 는 37 개 기본 피처에 22 개 cross-lag 피처를 추가한 확장 세트를 사용한다. 피처 수 차이는 불공정 비교가 아닌 각 모델의 최적 설계를 반영한 것이다.

본 연구의 모델은 두 가지 차별점을 갖는다. 첫째, 옵션 단면 데이터 없이 공개 OHLCV 와 VIX 기간구조만으로 문헌에서 보고된 최고 수준의 성능(표 12 참조)에 필적하거나 이를 상회하였다. 특히, 본 프레임워크와 동일 조건에서 평가된 전통적 시계열 모델인 GARCH(1,1) 및 GJR-GARCH(22d 풀링 $R^2 \approx 0.69$) 대비, 기본 선형 구조(HAR-3, 0.761)와 기계학습/정규화 앙상블(WEEns, 0.803)이 예측 성능을 대폭 상회함을 입증하였다. 둘째,

단일 자산(S&P 500)이 아닌 주식/채권/원자재 11 개 ETF 를 통합한 cross-asset 환경에서 일관되게 검증되었다.

4.4.2 딥러닝 피처 통제 효과 검증

가장 높은 성능을 낸 선형 모델(WEns) 군은 37 개 구조의 전체 피처 집합을 사용한 반면, BiLSTM-A 모델은 3 개의 range 피처에 국한된 설계값을 주었다는 부분에서 “선형 모델(37 피처) 대 딥러닝(3 변수)”이라는 불공정 비교(unfair comparison) 가능성이 제기될 수 있다. 이를 검증하고자 BiLSTM-A 모델에도 37 피처의 전체 피처를 동일하게 적용하여 재학습시키는 공정 비교 실험을 수행하였다. 그 결과, 1~22d 지평에서 폴링 R^2 가 기존 대비 큰 폭으로 하락한 0.538 이 산출되었다. 더불어 대다수 개별 자산(예: SPY -0.18, QQQ -0.81) 단위에서 딥러닝 예측치가 단순 역사적 평균치를 하회하는 강한 음수 중위 R^2 궤적을 남겼다(상세 표는 부록 참조). 이는 다수 피처가 교차하는 차원의 저주 제약에서 복잡한 신경망 구조가 강한 과적합 함정에 빠진 전형적인 양상을 증빙한다. 종합하면, BiLSTM-A 에 3 개의 range 핵심 피처만 입력한 의사 결정이 기계적으로 설정한 “불공정한 모델 축소”가 아니라 딥러닝의 과적합 통제를 위해 채택했던 최적의 정교한 피처 설계 선택이었음이 확인된다. 나아가 본 예측 환경하에서는 무조건적인 은닉 층 추가 등 단순 복잡성 증가보다 사전 피처 선택과 안정적 정규화 계열 구성이 시계열 예측성에 더 핵심임을 관찰하였다.

4.5 피처 기여 분석(Ablation)

피처 그룹이 실제로 예측력에 기여하는지 확인하기 위해 서브셋 실험을 수행하였다. 그 결과, HAR+Range(8 피처) 조합이 폴링 R^2 와 중위 R^2 모두에서 강한 성능을 보였고, 단순히 피처를 많이 넣는다고 성능이 항상 증가하지는 않았다.

표 10. 피처 서브셋 Ablation(요약, 22d)

Subset	#Feat P	ooled R^2 Medi	an R^2
HAR + Range	8	0.7854	0.1480
Range only	5	0.7722	0.0938
Full(37)	37	0.7618	0.0949
HAR only	3	0.7321	0.1678

이 결과는 1~22d 구간에서 WEns(37 피처 앙상블)이 풀링 $R^2 = 0.803$ 으로 가장 높은 성능을 기록한 사실과 모순되지 않는다. 즉, 기본 선형 구조에서는 HAR+Range 만으로도 충분히 강하지만, 고변동성 국면이나 22d 지평에서는 IV Surface/Alt Data 를 포함한 다수 피처 결합과 앙상블이 추가 개선을 제공할 수 있다(4.6 절 레짐 분석 참조).

4.5.1 피처 엔지니어링 누적 효과

표 11 는 피처 그룹을 단계적으로 추가할 때 성능이 어떻게 변화하는지를 보여준다. HAR 기본 3 개 피처(R^2 0.732)에서 출발하여 GARCH/Vol-of-Vol(+0.026), HF Proxy(+0.021), IV Surface(+0.011) 순으로 누적 개선되며, WEns 앙상블(0.803)과 ElasticNet-59(0.807)에서 최종적으로 R^2 0.80 벽을 돌파하였다.

표 11. 피처 엔지니어링 누적 효과 (그룹별 R^2 증가, 22d)

Stage	Features	Pooled R^2	Delta
HAR (base 3)	LogRV lags	0.732	-

4.5.2 ElasticNet 기반 최적 피처 선택 궤적(Path) 분석

ElasticNetCV 결과($n_splits=5$) $L1_ratio=1.0$, $\alpha=0.016$ 에서 최적화되어, 37 개 피처 중 17 개만 선택(sparsity 54%)되었다. 상위 3 개 피처는 LogRV_lag1(0.438),

RogersSatchell1_22(0.387), Parkinson_5(0.283)로, HAR 기본 피처 외에도 range 추정량·VIX 기간구조·GARCH 가 독립적인 정보 가치를 지님을 시사한다. | +GARCH+Vol-of-Vol | +GARCH Daily/Weekly, Std5/22 | 0.758 | +0.026 | | +HF Proxy(OHLC) | +Parkinson, GK, RS, Range/Close | 0.779 | +0.021 | | +IV Surface(VIX) | +VIX, VIX3M, VIX9D, Term Slope, VRP | 0.790 | +0.011 | | +Alt Data(Volume) | +Amihud, Vol Ratio, Kyle Lambda | 0.790 | +0.000 | | WEns | Ridge(70%)+XGBoost(30%) | 0.803 | +0.013 | | ElasticNet-59 | 59 extended feat. + L1+L2 | **0.807** | +0.004 |

4.5.3 다면적 피처 중요도 분석 (합의 순위)

단일 방법의 편향을 방지하기 위해 7 개 방법론(Ridge 정규화 계수, Permutation, XGBoost Gain, SHAP, Mutual Info, Spearman, RFE)의 중요도를 평균하여 표 12 의 합의 순위를 산출하였다.

표 12. 피처 중요도 합의 순위 (7 개 방법 평균)

Rank	Feature	Group	Mean Rank
1	RogersSatchell_22	HF Proxy	2.6
2	Garch_Weekly	GARCH	4.4
3	Parkinson_22	HF Proxy	5.1
4	GarmanKlass_22	HF Proxy	5.3
5	Garch_Daily	GARCH	6.7
6	LogRV_lag22	HAR	7.6
7	LogRV_lag1	HAR	9.1
8	Parkinson_5	HF Proxy	9.1
9	IV_VRP_ma22	IV Surface	11.7
10	IV_VIX	IV Surface	11.9

HF Proxy(range 기반) 피처가 상위 4 위 중 3 개를 차지하며, GARCH 피처가 그 다음으로 높은 순위를 기록하였다. IV Surface 피처는 상대적으로 낮은 순위이지만, 4.6 절의 레짐 분석에서 High VIX 구간의 추가 기여가 두드러지는 조건부 중요성을 보인다.

4.6 레짐(고변동성) 분석: High VIX 구간에서의 개선

VIX 분위수 기반 레짐 분석 결과, HAR-3 대비 WEns 의 개선 폭은 VIX 레짐에 따라 뚜렷이 달라졌다. Low VIX(하위 50%): R^2 0.739 $\rightarrow$ 0.781(+0.042), Mid VIX(50~90%): 0.698 $\rightarrow$ 0.722(+0.024)에 그친 반면, High VIX(상위 10%) 구간에서는 0.602 $\rightarrow$ 0.765(+0.163)으로 개선 폭이 가장 컸다.

이는 (i) IV Surface(기간구조, VRP 통계) 피처가 극단적 불확실성에서 추가 정보를 제공하고, (ii) HF proxy(range 계열)가 위기 시 확대되는 일중 변동을 포착하기 때문으로 해석할 수 있다.

이와 함께, 자산 클래스 및 모델 비교 기간(서브샘플)에 따른 이질성 분석 결과는 모형 개선의 양면성을 보여준다. HAR-3 대비 WEns 의 성능의 대폭 향상은 주로 주식(Equity) 패널에서 R^2 +0.163 개선으로 이끌었으나 원자재(Commodity)에서는 개선이 매우 둔화(-0.055)되는 양상을 띠었다. 또한, 2010-2014 기간에는 성능 향상이 뚜렷하나 2020 년 코로나 이후 국면에서는 단일 피처 모델 간 성능 우위 차이가 줄어드는 경향이 관찰되었다. 이는 모델이 특정 상황에 과적합되지 않도록 향후 자산 군집 별 또는 레짐 별 적응형 최적화(regularization) 적용의 당위성을 제공한다.

표 13 은 HAR-3 대비 WEns 의 자산군별 성능 개선폭을 시각화한 것이다.

표 13. 자산군별 HAR-3 vs WEns 성능 개선 비교 (22d 롤링 R²)

Asset	Class	HAR-3 R ²	WEns R ²	Delta
SPY	Equity	0.136	0.299	+0.163
QQQ	Equity	0.091	0.262	+0.171
IWM	Equity	0.088	0.215	+0.127
EFA	Equity	0.032	0.139	+0.107
EEM	Equity	-0.015	0.059	+0.074
TLT	Bond	0.015	-0.003	-0.018
IEF	Bond	0.022	0.030	+0.008
AGG	Bond	0.010	0.019	+0.009
GLD	Commodity	0.075	0.105	+0.030
SLV	Commodity	0.174	0.119	-0.055
USO	Commodity	-0.035	-0.081	-0.046

4.7 통계적 유의성: Diebold–Mariano(DM) 검정

22 거래일 지평에서는 Newey–West HAC(bandwidth=22)를 적용한 통계적 검정 결과, WEns 가중 앙상블은 HAR-3 대비 Diebold–Mariano 통계량 -8.80 ($p < 0.001$)을 기록하며 극히 유의미하게 우수하였다.

또한 지평별로 HAC bandwidth 를 h 로 두고 DM 검정을 확장한 결과, 축소 피쳐(9 개) 기반 비교에서는 예측 오차의 분산 축소 효과가 크지 않아 비교적 유의하지 않았으나, 다수 피쳐(37) 결합 앙상블은 매우 높은 신뢰도(1% 수준)로 기본 HAR 모형의 한계를 넘어섰다.

Newey–West HAC 검정(bandwidth= h)에서 WEns vs HAR-3 의 DM 통계량은 22d -8.802($p < 0.001$), 60d -7.481($p < 0.001$)이었으며, 블록 부트스트랩($B=5,000$)에서도 각각 -8.756, -7.593(모두 $p < 0.001$)으로 두 방법 모두 동일한 결론을 지지하였다.

4.8 강건성 검증 요약

표 11 는 WEns 앙상블에 대해 수행한 6 종 강건성 테스트의 결과를 종합적으로 정리한 것이다. 모든 항목에서 PASS 판정을 받았다.

표 11.6 종 강건성 테스트 종합표 (22d)

Validation	Result	Verdict
Multi-split stability	$R^2 = 0.793 \pm 0.010$ (5 splits)	Confirmed
Alpha sensitivity	$R^2 = 0.793 \sim 0.802$ ($\alpha \in [0.001, 5000]$)	Confirmed
5-Fold TS CV	$R^2 = 0.765 \pm 0.046$ (5-fold TimeSeriesSplit)	Confirmed
Data leakage test	Shuffled $R^2 = -0.002$ (no TS structure $\rightarrow$ no prediction)	Confirmed
Permutation Importance	Rogers-Satchell #1 (0.731), HF Proxy dominant	Confirmed
DM Test (Newey–West HAC)	All comparisons $p < 0.001$	Confirmed

추가로 Commodity IV 대체(GVZ/OVX) 실험에서 GLD +2.6%p, USO +0.8%p 개선이 있으나 전체 성능 변화는 -0.8%p 로 제한적이며, 단일 VIX proxy 사용의 타당성이 확인되었다. 블록 부트스트랩 DM 검정(block size=h, B=5,000)에서도 HAC 기반 DM 결과와 일치하여 유의성이 재확인되었다.

잔차 진단에서 비정규성(Jarque-Bera $p < 0.001$), 자기상관(Ljung-Box $p < 0.001$), ARCH 효과($p < 0.001$)가 관측되며, 이는 변동성 시계열의 일반적 특성으로 해석할 수 있다. 본 연구는 HAC 기반 검정과 블록 부트스트랩을 통해 이러한 특성이 통계적 비교에 미치는 영향을 완화하였다.

4.9 연구 질문(RQ)에 대한 답변

본 장의 실험 결과를 종합하여, 서론에서 제기한 네 가지 연구 질문에 답한다.

RQ1 (공개 데이터 기반 VRP 예측 가능성). 11 개 ETF(주식·채권·원자재) 패널에 대해 공개 OHLCV 와 VIX 기간구조만을 이용한 VRP 예측이 가능함을 확인하였다. 22d 지평에서 풀링 R^2 0.803 을 기록하였으며, HAR 모델 대비 유의미한 우위를 보였다.

RQ2 (지평별 성능·피처 변화). 단기에서는 HAR+Range(8 피처) 기반 다중 피처 결합이, 중기에서는 소수의 range 피처가 핵심 역할을 하며, 극단적 변동성 구간에서는 IV Surface 정보의 기여가 상승한다.

RQ3 (모델 구조별 상대 성능). 예측 지평에 따라 최적 모델 구조가 달라져, 1~22d 구간은 정규화 선형 앙상블, 60~90d 구간은 시계열 신경망, 180~252d 구간은 트리 모델이 가장 유리하게 작용하였다.

RQ4 (예측의 경제적 실효성). SPY 대상 VRP 신호 타이밍 전략 백테스트에서 거래비용(1bp)을 공제한 후에도 Buy & Hold 대비 위험 조정 수익률이 개선되어 경제적 실효성 가능성을 시사하였다(5.3 절).

5. 결론 및 향후 과제

5.1 연구 요약

본 연구는 공개적으로 이용 가능한 OHLCV 데이터와 변동성 지표만을 이용하여 주식, 채권, 원자재를 포괄하는 다중 자산 VRP 예측 프레임워크를 제안하였다. 2010 년 1 월 4 일부터 2024 년 12 월 31 일까지의 11 개 ETF 자료를 바탕으로, 미래 실현분산을 먼저 예측한 후 이를 내재분산 프록시와 결합하는 2 단계 구조를 설계하였다. 이 구조는 피처와 타깃에 동일한 IV 정보가 중복 투입되는 문제를 줄이고, RV 예측과 VRP 산출의 역할을 분리함으로써 해석 가능성을 높인다.

5.2 핵심 결과

실증 결과, 예측 지평에 따라 상대적으로 유리한 모형 구조가 달라지는 경향이 확인되었다. 단기 지평에서는 정규화 선형 모형이, 중기 지평에서는 시계열 신경망 모형이, 장기 지평에서는 트리 기반 모형이 상대적으로 안정적인 성능을 나타냈다. 특히 22 거래일 지평에서 제안한 weighted ensemble 은 Ridge 와 XGBoost 의 장점을 결합하여 우수한 성능을 보였으며, 70:30 가중치 역시 추가 실험을 통해 안정 구간 내의 보수적 선택으로 확인되었다. 또한 전방 채움 제거, 만기 불일치 점검, 자산특화 변동성 지표 적용 등 강건성 검증을 통해 핵심 결론이 특정 처리 방식에 과도하게 의존하지 않음을 확인하였다.

5.3 경제적 함의 및 연구 의의

경제적 활용 측면에서는 SPY 를 대상으로 한 단순 타이밍 전략에서 Buy-and-Hold 대비 샤프 비율이 0.705 에서 0.804 로, 연환산 수익률이 12.37%에서 19.44%로 개선되는 결과가 관찰되었다. 다만 이는 탐색적 결과이며, 통계적으로 강한 유의성을 확보한 결론으로 일반화하기보다는 실무적 가능성을 보여주는 보조 증거로 해석할 필요가 있다. 그럼에도 본 연구는 공개 데이터 기반으로 재현 가능한 cross-asset VRP 예측 체계를 제시하고, 다중 예측 지평에서 모형 구조의 상대적 적합성이 달라질 수 있음을 실증적으로 보여주었다는 점에서 의의를 가진다.

References

- [1] S. Gu, B. Kelly, and D. Xiu, "Empirical asset pricing via machine learning", *The Review of Financial Studies*, Vol. 33, No. 5, pp. 2223-2273, May 2020.
- [2] F. Corsi, "A simple approximate long-memory model of realized volatility", *Journal of Financial Econometrics*, Vol. 7, No. 2, pp. 174-196, Mar. 2009.
- [3] F. Audrino and S. Knaus, "Lassoing the HAR model: A model selection perspective on realized volatility dynamics", *Journal of Financial Econometrics*, Vol. 14, No. 2, pp. 392-427, 2016.
- [4] K. Christensen, M. Siggaaard, and B. Veliyev, "Volatility forecasting with machine learning and intraday commonality", *Journal of Financial Econometrics*, Vol. 22, No. 1, pp. 1-35, Jan. 2024.
- [5] P. Carr and L. Wu, "Variance risk premia", *The Review of Financial Studies*, Vol. 22, No. 3, pp. 1311-1341, Mar. 2009.
- [6] G. Bekaert and M. Hoerova, "The VIX, the variance premium and stock market volatility", *ECB Working Paper*, No. 1675, 2014.
- [7] T. Bollerslev, G. Tauchen, and H. Zhou, "Expected stock returns and variance risk premia", *The Review of Financial Studies*, Vol. 22, No. 11, pp. 4463-4492, Nov. 2009.
- [8] I. Drechsler and A. Yaron, "What's vol got to do with it", *The Review of Financial Studies*, Vol. 24, No. 1, pp. 1-45, Jan. 2011.
- [9] B. Zhang, Y. Chen, and Y. Lu, "Nonparametric estimation of variance risk premiums", *Journal of Financial Economics*, Vol. 142, No. 1, pp. 312-328, Oct. 2021.

- [10] M. Hattori, I. Shim, and Y. Sugihara, "The US variance risk premium and cross-market spillovers", Bank for International Settlements Working Paper, No. 713, Apr. 2018.
- [11] J. R. Ornelas et al., "Volatility risk premia and future commodity returns", Bank for International Settlements Working Paper, No. 619, 2018.
- [12] R. F. Engle, "Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation", *Econometrica*, Vol. 50, No. 4, pp. 987-1007, 1982.
- [13] T. Bollerslev, "Generalized autoregressive conditional heteroskedasticity", *Journal of Econometrics*, Vol. 31, No. 3, pp. 307-327, 1986.
- [14] P. Carr, L. Wu, and Z. Zhang, "Using machine learning to predict realized variance", arXiv preprint, 2019.
- [15] T. Dierckx, M. Davis, and W. Schoutens, "Machine learning for the FX variance risk premium", *Quantitative Finance*, Vol. 22, No. 1, pp. 129-143, Jan. 2022.
- [16] S. Heston and V. Todorov, "Exploring the variance risk premium across assets", AEA Conference Paper, 2024.
- [17] M. López de Prado, "Advances in financial machine learning", Wiley, 2018.

Appendix (부록)

A. 피처 구성 및 방법론 상세

표 A-1. 37 개 피처 상세 목록 (WEEns Ridge 기준)

#	Group	Variable	Calculation & Description
1	HAR	LogRV_lag1	Prev-day Log-RV: $\log(RV_{t-1})$
2	HAR	LogRV_lag5	5d lag Log-RV: $\log(RV_{t-5})$
3	HAR	LogRV_lag10	10d lag Log-RV: $\log(RV_{t-10})$
4	HAR	LogRV_lag22	22d lag Log-RV: $\log(RV_{t-22})$
5	GARCH	Garch_Daily	Daily GARCH(1,1) vol (rolling fit)
6	GARCH	Garch_Weekly	Weekly GARCH vol (weekly returns)
7	HAR	LogRV_Std5	5d Vol-of-Vol: $\text{std}(\log RV, 5d)$
8	HAR	LogRV_Std22	22d Vol-of-Vol: $\text{std}(\log RV, 22d)$
9	HAR	RV_Mom5	5d vol momentum
10	HAR	RV_Mom22	22d vol momentum
11	Cross	SPY_LogRV	SPY Log-RV (market ref)

#	Group	Variable	Calculation & Description
12	HAR	Ret_lag1	Prev-day log return
13	HAR	Ret_abs_lag1	Prev-day abs return
14	Cross	Corr_SPY	SPY corr (22d rolling)
15	HF	Parkinson_5	5d Parkinson vol
16	HF	Parkinson_22	22d Parkinson vol
17	HF	GarmanKlass_22	22d Garman-Klass vol
18	HF	RogersSatchell_22	22d Rogers-Satchell vol
19	HF	Range_Close_Ratio	Range-close ratio
20	HF	Overnight_Vol	Overnight vol
21	HF	Overnight_Ret	Overnight return
22	IV	IV_VIX	VIX level: $\log(\text{VIX})$
23	IV	IV_VIX_chg	VIX daily change
24	IV	IV_VIX_ma5	VIX 5d MA
25	IV	IV_VIX_std5	VIX 5d std (VVIX proxy)
26	IV	IV_VIX3M	VIX3M level: $\log(\text{VIX3M})$
27	IV	IV_VIX_TermSlope	VIX term slope
28	IV	IV_VIX9D	VIX9D level: $\log(\text{VIX9D})$
29	IV	IV_VIX_ShortSlope	VIX9D slope
30	IV	IV_VRP	VRP proxy: $\text{VIX}^2/100 - \text{RV_SPY}$
31	IV	IV_VRP_ma22	VRP 22d MA
32	Alt	AltVol_Amihud	Amihud illiquidity (22d)
33	Alt	AltVol_Vol_Ratio	Volume ratio (short/long)
34	Alt	AltVol_PV_Corr	Price-volume corr
35	Alt	AltVol_Vol_Surprise	Volume surprise (Z-score)
36	Alt	AltVol_Order_Imbalance	Signed volume imbalance
37	Alt	AltVol_Kyle_Lambda	Kyle Lambda (price impact)

표 A-2. 정규화 계열 알고리즘의 선형-비선형 특성 구조 비교표

Method	Penalty	Feat Select	Multicollinearity	Overfitting Control
L1 (LASSO)	λ $ \beta _1$	O	Selects one among correlated feat (Sparsity)	Shrinks minor coefs to exact zero

Method	Penalty	Feat Select	Multicollinearity	Overfitting Control
L2 (Ridge)	$\alpha + \beta _2^2$	X	Retains all correlated feat, shrinks variance	Improves condition number of $X^T X$
ElasticNet	$\rho L1 + (1-\rho)L2$	Yes	L1+L2 mix (group selection/retention)	Hyperparameter-based feat selection
Dropout(DL)	Structural node dropout	No	Differs from linear	Random node removal during training

Ridge 수학적 구조: WEns의 핵심 모델인 Ridge 회귀의 해석적 해(closed-form)는 $\hat{\beta}_{\text{Ridge}} = (X^T X + \alpha I)^{-1} X^T y$ 로 계산되어, X 행렬의 상관성이 높을 때 분산을 획기적으로 낮출 수 있으며 37개 변수 모두를 보존하는 특성을 갖는다.

B. 성능 분포 보충 근거

표 A-3. Range 기반 추정량의 이론적 효율성 비교

Estimator	Formula	Efficiency	Application
Close-to-Close	$(C-O)^2$	1.0x (Baseline)	Not used (baseline RV)
Parkinson	$\propto (H-L)^2$	5.0x	5d, 22d feat
Rogers-Satchell	$(H-C)(H-O) + (L-C)(L-O)$	5.0x (Drift-robust)	BiLSTM-A top feat
Garman-Klass	$0.5(H-L)^2 - (C-O)^2$	7.4x	BiLSTM-A feat, WEns #2

참고: BiLSTM-A는 소수의 range 피처만으로도 경쟁력 있는 성능을 보였으며, 피처 수를 크게 늘리지 않고도 중기 지평에서 유의미한 예측력을 확보할 수 있음을 시사한다. 피처 수별 성능 분포는 표 7의 동일 조건 비교를 참조한다.

표 A-4. 모델 복잡도(파라미터 수) vs 22d 예측 성능 (R^2)

Model	~Params	Pooled R^2
GARCH	~5	0.550

Model	~Params	Pooled R^2
HAR-3	~4	0.761
Ridge (per-class)	~38	0.762
Random Forest	~1,000	0.770
BiLSTM-A	~9,000	0.780
Transformer	~85,000	0.534 (Overfitting)

종합: 변동성 예측 환경 특유의 고잡음 환경에서는 수만 개의 파라미터를 가진 거대 딥러닝 보다는 정교하게 설계된 10 만 개 이하의 모델(BiLSTM-A)이나, 소수의 피처로 최적 규제를 건 선형 모델(Ridge, 38 파라미터) 구조가 안정적인 성능을 달성함을 시사한다.

C. 기타 비교 모델 하이퍼파라미터 상세 설정

본 연구의 성능 비교군으로 사용된 정규화 선형 모델(Lasso, Ridge), 커널 기반 모델(SVR), 신경망 모델(MLP)의 상세 설정은 표 A-5 와 같다. 모든 파라미터는 학습 데이터셋에서의 시계열 교차검증을 통해 최적화되었거나, 과적합 방지를 위한 표준적인 규제 강도를 채택하였다.

표 A-5. 기타 비교 모델 하이퍼파라미터 설정 요약

Model	Hyperparameter	Value	Description
Ridge	alpha	10.0	L2 regularization strength
Lasso	alpha	0.01	L1 regularization strength
ElasticNet	alpha	0.01	Total regularization strength
	l1_ratio	0.5	Mix of L1 (0.5) and L2 (0.5)
SVR	kernel	‘rbf’	Radial Basis Function kernel
	C	10.0	Regularization parameter
	epsilon	0.1	Epsilon-tube width
MLP	hidden_layer_sizes	(64, 32)	Two-layer architecture
	activation	‘relu’	Rectified Linear Unit
	early_stopping	True	Terminate if val-loss plateaus
	random_state	42	Deterministic initialization
Random Forest	n_estimators	200	Number of trees
	min_samples_leaf	20	Minimum samples in leaf node

Model	Hyperparameter	Value	Description
XGBoost	n_estimators	300	Boosting rounds
	learning_rate (η)	0.05	Learning rate
	reg_lambda (L_2)	1.0	L2 regularization
LightGBM	n_estimators	300	Boosting rounds
	num_leaves	31	Max leaves in one tree

본 연구의 모든 비교 모델들의 최종 하이퍼파라미터는 학습 구간 내 5-fold TimeSeriesSplit(시계열 교차검증)을 통해 탐색 및 선택되었으며, 표 A-5 는 그 최종 결과치를 요약한 것이다.